UNIVERZITET U NOVOM SADU
FAKULTET TEHNIČKIH NAUKA
U NOVOM SADU

Богдан Ђукић

Визуелно разумевање сцене кроз неуросимболичко резоновање

Дипломски рад

- Основне академске студије -

Нови Сад, 2026.

	УНИВЕРЗИТЕТ У НОВОМ САДУ **ФАКУЛТЕТ ТЕХНИЧКИХ НАУКА** 21000 НОВИ САД, Трг Доситеја Обрадовића 6	Датум:
	ЗАДАТАК ЗА ИЗРАДУ ДИПЛОМСКОГ (BACHELOR) РАДА	Лист: 1/1

(Податке уноси предметни наставник - ментор)

Врста студија:	**Основне академске студије**
Студијски програм:	**Рачунарство и аутоматика**
Руководилац студијског програма:	**проф др. Иван Каштелан**

Студент:	**Богдан Ђукић**	Број индекса:	**РА 98/2021**
Област:	**Електротехничко и рачунарско инжењерство**		
Ментор:	**др Милан Сегединац, редовни професор**		

НА ОСНОВУ ПОДНЕТЕ ПРИЈАВЕ, ПРИЛОЖЕНЕ ДОКУМЕНТАЦИЈЕ И ОДРЕДБИ СТАТУТА ФАКУЛТЕТА ИЗДАЈЕ СЕ ЗАДАТАК ЗА ДИПЛОМСКИ РАД, СА СЛЕДЕЋИМ ЕЛЕМЕНТИМА:

- проблем – тема рада;
- начин решавања проблема и начин практичне провере резултата рада, ако је таква провера неопходна;
- литература

НАСЛОВ ДИПЛОМСКОГ (BACHELOR) РАДА:

Визуелно разумевање сцене кроз неуросимболичко резоновање

ТЕКСТ ЗАДАТКА:

1. Анализирати стање у области визуелног одговарања на питања.
2. Дефинисати захтеве система: изградња графа сцене из слике, превођење питања у DSL програм и његово симболичко извршавање.
3. Пројектовати модуларну архитектуру са графом сцене као интерфејсом између перцепције и резоновања.
4. Имплементирати решење применом модела YOLOv8, FastSAM, MiDaS, CLIP и T5-small.
5. Валидирати систем на CLEVR скуповима уз анализу грешака по компонентама.
6. Дискутовати резултате и смернице за будући рад.Humans, у токовима са референтним и детектованим графом сцене, уз додатно обучавање алгоритмом REINFORCE.

Руководилац студијског програма:	Ментор рада:

Примерак за: ☐ - Студента; ☐ - Ментора

КЉУЧНА ДОКУМЕНТАЦИЈСКА ИНФОРМАЦИЈА

Редни број, **РБР**:	
Идентификациони број, **ИБР**:	
Тип документације, **ТД**:	монографска публикација
Тип записа, **ТЗ**:	текстуални штампани документ
Врста рада, **ВР**:	дипломски рад
Аутор, **АУ**:	Богдан Ђукић
Ментор, **МН**:	др Милан Сегединац, редовни професор
Наслов рада, **НР**:	Визуелно разумевање сцене кроз неуросимболичко резоновање
Језик публикације, **ЈП**:	српски
Језик извода, **ЈИ**:	српски / енглески
Земља публиковања, **ЗП**:	Србија
Уже географско подручје, **УГП**:	Војводина
Година, **ГО**:	2026

Издавач, **ИЗ**:	ауторски репринт
Место и адреса, **МА**:	Нови Сад, Факултет техничких наука, Трг Доситеја Обрадовића 6
Физички опис рада, **ФО**:	7 / 77 / 28 / 15 / 6 / 0 / 0
Научна област, **НО**:	Софтверско инжењерство и информационе технологије
Научна дисциплина, **НД**:	Софтверско инжењерство
Предметна одредница / кључне речи, **ПО**:	Визуелно одговарање на питања, неуросимболичко резоновање, CLEVR, рачунарска визија
УДК	
Чува се, **ЧУ**:	Библиотека Факултета техничких наука, Трг Доситеја Обрадовића 6, Нови Сад
Важна напомена, **ВН**:	
Извод, **ИЗ**:	У раду је описан неуросимболички систем за визуелно одговарање на питања који раздваја перцепцију од резоновања. Слика се преводи у граф сцене, питање у DSL програм који се симболички извршава, а систем је евалуиран на CLEVR скуповима уз анализу грешака по фазама.
Датум прихватања теме, **ДП**:	
Датум одбране, **ДО**:	03.07.2026.
Чланови комисије, **КО**:	
председник	др Милан Видаковић, редовни професор
члан	др Марко Марковић, ванредни професор
ментор	др Милан Сегединац, редовни професор
Потпис ментора	

KEY WORDS DOCUMENTATION

Accession number, **ANO**:	
Identification number, **INO**:	
Document type, **DT**:	monographic publication
Type of record, **TR**:	textual material
Contents code, **CC**:	Bachelor thesis
Author, **AU**:	Bogdan Dukic
Mentor, **MN**:	Milan Segedinac, full professor, PhD
Title, **TI**:	Visual Scene Understanding through Neurosymbolic Reasoning
Language of text, **LT**:	Serbian
Language of abstract, **LA**:	Serbian / English
Country of publication, **CP**:	Serbia
Locality of publication, **LP**:	Vojvodina
Publication year, **PY**:	2026
Publisher, **PB**:	author's reprint
Publication place, **PP**:	Novi Sad, Faculty of Technical Sciences, Trg Dositeja Obradovića 6
Physical description, **PD**:	7 / 77 / 28 / 15 / 6 / 0 / 0
Scientific field, **SF**:	Software Engineering and Information Technologies
Scientific discipline, **SD**:	Software Engineering
Subject / Keywords, **S/KW**:	Visual Question Answering, Neurosymbolic Reasoning, CLEVR, Computer Vision
UDC	

Holding data, **HD**:	Library of the Faculty of Technical Sciences, Trg Dositeja Obradovića 6, Novi Sad
Note, **N**:	
Abstract, **AB**:	This paper describes a neurosymbolic visual question answering system that separates perception from reasoning. The image is translated into a scene graph, and the question into a DSL program that is executed symbolically; the system is evaluated on the CLEVR datasets with a per-stage error analysis.
Accepted by sci. Board on, **ASB**:	
Defended on, **DE**:	
Defense board, **DB**:	
president	Milan Vidakovic, full professor, PhD
member	Milan Segedinac, full professor, PhD
mentor	Marko Markovic, associate professor,PhD
Mentor's signature	

Садржај

1.УВОД 1
2. ПРЕГЛЕД СТАЊА У ОБЛАСТИ 3
2.1. Рани скупови за VQA и постављање проблема 3
2.2. Модуларне неуронске мреже и неуросимболички системи 4
2.3. Потпуно неуронски модели са високим резултатима 5
2.4. Прелаз ка реалним сценама и програмски LLM приступи 5
2.5. Рад најближи предложеном решењу 6
2.6. Закључак прегледа 7
3. ТЕОРИЈСКИ ПОЈМОВИ И ДЕФИНИЦИЈЕ 8
3.1. Визуелно одговарање на питања и неуросимболички приступи 8
3.2. Граф сцене 9
3.3. Неуронске мреже у рачунарском виду 9
3.4. Модели рачунарског вида за анализу сцене 10
3.4.1. Детекција објеката и YOLOv8 11
3.4.2. Сегментација инстанци и FastSAM 12
3.4.3. Процена дубине из слике и MiDaS 12
3.4.4. Екстракција визуелних атрибута и CLIP 13
3.5. Трансформерски модели за обраду природног језика и T5 14
3.5.1. Трансформерска архитектура и механизам пажње 14
3.5.2. T5 и семантичко парсирање 15
3.5.3. Велики језички модели 15
3.5.4. Учење поткрепљивањем и алгоритам REINFORCE 16
3.6. Доменски специфични језик и симболичко извршавање 17
4. МЕТОДОЛОГИЈА 18
4.1. Архитектура система 18

4.2. Детекција и сегментација објеката 21
4.2.1. Хибридни детектор 21
4.2.2. Сегментација по граничном оквиру 23
4.3. Процена дубине и резолуција преклапања маски 23
4.3.1. Монокуларна процена дубине 24
4.3.2. Резолуција преклапања маски применом Z-бафера 25
4.4. Екстракција атрибута и просторних односа 26
4.4.1. Екстракција атрибута применом CLIP-а 26
4.4.2. Израчунавање просторних односа 27
4.5. Изградња графа сцене 27
4.5.1. Формат графа сцене 28
4.5.2. Визуализација графа сцене 29
4.6. Превођење питања у DSL програм 29
4.6.1. Типови података и оператори DSL-а 30
4.6.2. Линеаризација програма за тренирање 30
4.6.3. Додатно обучавање T5-small модела 31
4.6.4. Инференца и валидација програма 31
4.7. Симболичко извршавање 32
4.8. Коришћени алати 33
5. ЕКСПЕРИМЕНТИ 34
5.1. Скупови података 34
5.1.1. CLEVR 34
5.1.2. CLEVR-CoGenT 36
5.1.3. CLEVR-Humans 36
5.1.4. Сумарни преглед скупова података 37
5.2. Евалуациона поставка 38
5.2.1. Токови евалуације 38

5.2.2. Формирање евалуационих подскупова 38
5.2.3. Категорије питања 39
5.2.4. Мере перформанси 40
5.3. Додатно обучавање компонената система 41
5.3.1. Додатно обучавање детектора YOLOv8 41
5.3.2. Додатно обучавање T5-small модела на CLEVR скупу 42
5.3.3. Додатно обучавање T5-small применом алгоритма REINFORCE 43
5.4. Генерализација модула за превођење питања у DSL 44
5.5. Евалуација система са детектованим графом сцене 45
5.6. Директна евалуација перцептивне компоненте 46
6. РЕЗУЛТАТИ И ДИСКУСИЈА 48
6.1. Резултати додатног обучавања T5-small модела на CLEVR скупу 48
6.2. Резултати генерализације модула за превођење питања у DSL програме 50
6.3. Резултати директне евалуације перцептивне компоненте 52
6.3.1. Квалитет детекције објеката 52
6.3.2. Тачност класификације атрибута 53
6.3.3. Детаљна анализа грешака перцептивне компоненте 54
6.4. Резултати евалуације комплетног система 56
6.5. Поређење резултата са блиским радовима из области 57
7. ЗАКЉУЧАК 60
ЛИТЕРАТУРА 64
БИОГРАФИЈА 68

1. УВОД

Визуелно одговарање на питања представља мултимодални задатак у коме је, на основу слике и питања формулисаног на природном језику, потребно одредити тачан одговор (енгл. *Visual Question Answering,* VQA) [1]. Овај задатак захтева истовремену анализу визуелног садржаја, разумевање језичке структуре питања и извођење закључка на основу информација из оба модалитета. На основу тога се налази на пресеку рачунарског вида, обраде природног језика и машинског резоновања.

Мотивација за решавање овог проблема произлази из ограничења савремених потпуно неуронских приступа. Иако такви модели могу постићи високу тачност на стандардним скуповима података, њихов поступак закључивања најчешће није експлицитан. У случају погрешног одговора тешко је утврдити да ли је грешка настала приликом препознавања објеката, разумевања питања, праћења просторних односа или самог резоновања. Због тога су приступи који омогућавају јаснију анализу појединачних фаза система посебно значајни.

Специфичан проблем који се решава у овом раду јесте развој система за визуелно одговарање на питања над синтетичким сценама, са нагласком на интерпретабилности и могућности анализе грешака. Улаз у систем чине слика и питање на природном језику, док је излаз одговор који може бити број, вредност атрибута или потврдан, односно одречан исказ. Питања обухватају различите типове резоновања, као што су препознавање атрибута, бројање, поређење и праћење просторних односа између објеката.

Решење је засновано на неуросимболичкој архитектури која раздваја перцепцију од резоновања. Перцептивна компонента из улазне слике гради структурисани граф сцене, у коме су објекти описани атрибутима и међусобним просторним односима. За изградњу графа сцене коришћени су модели рачунарског вида за детекцију, сегментацију, процену дубине и класификацију атрибута. Са друге стране, питање на природном језику преводи се у програм на доменски

специфичном језику, који се затим симболички извршава над графом сцене.

Систем је евалуиран у два тока: у референтном току, у коме се користи анотирани граф сцене, и у реалистичнијем току, у коме се граф сцене аутоматски изграђује из улазне слике. Евалуација је спроведена на скуповима из CLEVR [2] породице. Резултати показују да модул за превођење питања у програм постиже веома високу тачност у референтном току, док у комплетном систему главно ограничење представља перцептивна компонента.

Остатак рада организован је на следећи начин. У поглављу 2 дат је преглед постојећих приступа и методологија релевантних за визуелно одговарање на питања, са посебним осртом на неуросимболичке архитектуре. Поглавље 3 уводи теоријске појмове и алгоритме неопходне за разумевање предложеног система. У поглављу 4 описани су методологија и архитектура система. Поглавље 5 представља експерименталну поставку, коришћене скупове података и мере евалуације. У поглављу 6 приказани су резултати експеримената и дискусија добијених налаза, док поглавље 7 износи закључке рада и могуће правце даљег унапређења.

2. ПРЕГЛЕД СТАЊА У ОБЛАСТИ

У овом поглављу приказани су постојећи приступи и методологије релевантни за проблем визуелног одговарања на питања уз примену неуросимболичких архитектура. Критеријум за избор радова обухватио је три групе: радове који директно решавају VQA, моделе и системе засноване на модуларном и програмском резоновању, као и радове који су архитектурно и методолошки најближи предложеном решењу. Радови су приказани хронолошки, како би се истакао развој приступа од потпуно неуронских ка неуросимболичким архитектурама, уз посебан осврт на радове најближе предложеном систему.

2.1. Рани скупови за VQA и постављање проблема

Савремени облик задатка визуелног одговарања на питања формализован је у раду *VQA: Visual Question Answering* [1], у ком је приказан скуп са 250.000 слика и 760.000 питања. Већ у раним истраживањима показало се да модели могу постизати високу тачност ослањајући се на статистичке пристрасности у подацима. На пример, одговор „да“ на питања облика „да ли...?“ често је исправан и без стварне анализе визуелног садржаја. То је указало на то да висока тачност на раним VQA скуповима не мора нужно значити и стварно визуелно резоновање, што је подстакло развој дијагностичких скупова података.

Значајан корак у том правцу доноси рад *CLEVR: A Diagnostic Dataset for Compositional Language and Elementary Visual Reasoning* [2], у ком је представљен синтетички скуп **CLEVR** са контролисаним тродимензионалним сценама, 853.554 јединствених питања и придруженим функционалним програмима. CLEVR је омогућио детаљну анализу различитих типова резоновања, као што су бројање,

поређење и праћење просторних односа, уз знатно мањи утицај нежељених статистичких правилности карактеристичних за природне фотографије. Његово ограничење огледа се у унапред дефинисаном скупу атрибута и синтетичкој природи сцена, због чега је задатак у извесној мери једноставнији него у реалном окружењу.

2.2. Модуларне неуронске мреже и неуросимболички системи

Рана идеја модуларности у VQA-у уведена је у раду *Neural Module Networks* (**NMN**) [3] из 2016. године. Основна идеја овог приступа јесте да се за свако питање динамички формира мрежа специјализованих неуронских модула, чиме се у иначе монолитне моделе уноси видљива структура извршавања. Главна слабост NMN-а је зависност од спољашњег синтаксичког парсера, што приступ чини осетљивим на формулацију питања.

Тај недостатак делимично је ублажен у раду *Learning to Reason: End-to-End Module Networks for Visual Question Answering* (**N2NMN**) [4], у коме систем сам учи распоред модула из података. На CLEVR скупу овај приступ постиже 83,7% тачности. Иако је тиме побољшана прилагодљивост, само извршавање је остало у потпуности неуронско, без формалног и проверљивог трага резоновања.

Значајан корак у том правцу представља рад *Inferring and Executing Programs for Visual Reasoning* (IEP) [5]. **IEP** уводи генератор програма на основу питања, чији се излаз затим прослеђује извршном механизму. У снажно надгледаној варијанти систем постиже 96,9% тачности на CLEVR-у. Значај овог рада огледа се у јасном раздвајању фазе генерисања програма од фазе његовог извршавања, иако сам механизам извршавања остаје неуронски.

2.3. Потпуно неуронски модели са високим резултатима

Паралелно са модуларним приступима развијали су се и потпуно неуронски модели који су на скупу CLEVR постизали веома високе резултате, иако нису користили експлицитну симболичку структуру.

Један од таквих приступа описан је у раду *FiLM: Visual Reasoning with a General Conditioning Layer* [6], у коме се визуелне карактеристике условљавају информацијом добијеном из питања. Овај модел постиже 97,7% тачности на CLEVR-у. Његово главно ограничење огледа се у томе што ток резоновања није формално експлицитан, због чега је тешко поуздано одредити у којој фази обраде долази до грешке.

Слично томе, у раду *Compositional Attention Networks for Machine Reasoning* [7] предложен је модел заснован на итеративним корацима резоновања вођеним механизмом пажње. Овај приступ постиже 98,9% тачности на CLEVR-у и у односу на типичне потпуно неуронске моделе нуди нешто јаснију унутрашњу структуру обраде. Ипак, поступак извршавања и даље није формалан нити симболички проверљив.

Ови модели су значајни јер показују да је и без експлицитне симболичке структуре могуће постићи веома високу тачност на дијагностичким скуповима као што је CLEVR. Истовремено, њихова ограничена интерпретабилност указује на разлику између високе перформансе и могућности формалног праћења поступка резоновања.

2.4. Прелаз ка реалним сценама и програмски LLM приступи

Са преласком са синтетичких на реалне сцене, задатак визуелног одговарања на питања постаје знатно сложенији. У том контексту значајан је скуп **GQA** (*Graph Question Answering*) [8], заснован на реалним сликама и густим анотацијама графова сцене. За

разлику од синтетичких скупова као што је CLEVR, GQA у већој мери одражава сложеност стварног визуелног окружења, па јасније показује да висока тачност на контролисаним скуповима не значи нужно и успешно резоновање у реалним условима.

У новијем периоду појављују се приступи који задржавају идеју програмског резоновања, али уместо фиксног доменски специфичног језика користе велике језичке моделе. Рад *Visual Programming: Compositional Visual Reasoning Without Training* [9] приказује систем у коме језички модел генерише програм који се извршава над специјализованим визуелним алатима, док *ViperGPT* (*Visual Inference via Python Execution for Reasoning*) [10] додатно проширује ову идеју на флексибилније и отвореније сценарије. Заједничка предност ових приступа је већа флексибилност, док се ограничења огледају у зависности од текстуалног упита и спољашњих алата, што отежава строго контролисану анализу појединачних компоненти.

2.5. Рад најближи предложеном решењу

Рад најближи предложеном систему јесте *Neural-Symbolic VQA: Disentangling Reasoning from Vision and Language Understanding* [11]. У овом раду предложена је архитектура заснована на јасном раздвајању три компоненте: анализе сцене, парсирања питања и симболичког извршавања. Визуелна компонента формира структурисан граф сцене у коме су објекти описани дискретним атрибутима, док се питање преводи у програм који се затим извршава над тако добијеном репрезентацијом. На тај начин одговор се добија симболичким поступком, што омогућава проверљив и интерпретабилан ток закључивања.

У раду је пријављена тачност од 99,8% на скупу CLEVR, уз релативно мали број програмских анотација и слика за обучавање парсера сцене. Посебан значај овог приступа огледа се у томе што показује да је могуће раздвојити перцепцију од резоновања и на тај начин добити систем који је истовремено прецизан и интерпретабилан. Ограничење овог решења лежи у зависности од квалитета сценског

парсера, као и у ослањању на унапред дефинисан скуп атрибута, што ограничава примену у сложенијим и отворенијим визуелним окружењима.

Предложени дипломски рад полази од исте основне архитектурне идеје, односно од раздвајања перцептивне компоненте, обраде питања и симболичког извршавања. Због чега овај рад представља најближу референтну тачку и природно полазиште за предложено решење.

2.6. Закључак прегледа

Историјски посматрано, развој визуелног одговарања на питања може се сагледати кроз три основне фазе. Прву фазу обележили су рани VQA скупови и потпуно неуронски модели, код којих је уочено да висока тачност често произлази из ослањања на статистичке правилности у подацима, а не из стварног визуелног резоновања. Другу фазу обележили су модуларни и неуросимболички системи, посебно IEP и *Neural-Symbolic VQA: Disentangling Reasoning from Vision and Language Understanding*, уз CLEVR као централни дијагностички скуп. Трећу фазу чине приступи засновани на великим језичким моделима и програмском резоновању, који омогућавају већу флексибилност и ширу примену, али уз мање контролисану интерпретабилност.

3. ТЕОРИЈСКИ ПОЈМОВИ И ДЕФИНИЦИЈЕ

У овом поглављу приказани су теоријски појмови и алгоритми неопходни за разумевање развијеног неуросимболичког система за визуелно одговарање на питања над сликама. Циљ поглавља није опис конкретне имплементације предложеног решења, већ представљање теоријских основа на којима се оно заснива. Због тога су у наставку најпре описани основни концепти визуелног одговарања на питања и неуросимболичких приступа, затим граф сцене као структурисана репрезентација визуелног садржаја, потом модели рачунарског вида који омогућавају изградњу такве репрезентације, као и трансформерски модели за пресликавање питања са природног језика у формални програм. На крају су описани доменски специфични језици и симболичко извршавање, који чине основу резоновања у предложеном систему.

3.1. Визуелно одговарање на питања и неуросимболички приступи

Визуелно одговарање на питања (VQA) је мултимодални задатак у коме је, на основу слике и питања формулисаног на природном језику, потребно одредити тачан одговор. За разлику од класичних задатака рачунарског вида или обраде природног језика, VQA захтева истовремену анализу визуелног садржаја, разумевање језичке структуре питања и извођење закључка на основу информација из оба модалитета. У зависности од типа питања, од система се може захтевати препознавање објеката и њихових атрибута, утврђивање просторних односа, бројање, поређење и вишекорачно резоновање.

Савремени приступи овом проблему могу се грубо поделити на потпуно неуронске и неуросимболичке. **Потпуно неуронски**, (енгл. *end-to-end*) системи, уче директно пресликавање из улазног пара слика-

питање у одговор, без експлицитног издвајања међукорака резоновања. **Неуросимболички** приступи, насупрот томе, раздвајају процес перцепције од процеса резоновања: неуронске компоненте користе се за издвајање информација из слике и текста, док се коначан одговор добија симболичким извршавањем формално дефинисаних операција над структурисаном репрезентацијом сцене. Оваква организација омогућава да ток резоновања буде експлицитнији и погоднији за анализу појединачних фаза обраде.

3.2. Граф сцене

Граф сцене чини структурисану репрезентацију визуелне сцене у којој чворови одговарају објектима, а гране односима између тих објеката. У контексту визуелног одговарања на питања, оваква репрезентација омогућава да се елементи сцене представе у експлицитном облику погодном за формално резоновање. На тај начин се резултати перцепције преводе у структуру над којом је могуће извршавати јасно дефинисане операције.

Чворови графа сцене описују појединачне објекте помоћу дискретних атрибута, као што су боја, облик, материјал и величина, док гране кодирају просторне односе између објеката. Оваква организација омогућава примену операција филтрирања, издвајања атрибута, праћења релација и бројања, без потребе за додатним неуронским декодовањем у фази резоновања.

3.3. Неуронске мреже у рачунарском виду

Сви модели рачунарског вида коришћени у овом раду засновани су на дубоким неуронским мрежама [12]. Вештачка неуронска мрежа (енгл. *Artificial Neural Network*, ANN) је математички модел инспирисан радом биолошких неурона. Основни елемент је неурон који прима скуп улазних вредности $x_1, \cdots, x_n$, сваком придружује тежину w_i, рачуна

линеарну комбинацију са слободним чланом b и кроз нелинеарну активациону функцију f производи излаз:

$$y = f\left(\sum_{i=1}^{n} w_i x_i + b\right)$$

Мрежа је организована у слојеве: улазни слој прима податке, скривени слојеви уче апстрактне представе, а излазни слој даје коначни резултат. Тежине се оптимизују током тренинга путем алгоритма повратног простирања грешке (енгл. *backpropagation*) и градијентног спуста [13].

Конволуционе неуронске мреже (енгл. *Convolutional Neural Networks*, CNN) специјализована су врста мрежа прилагођена за обраду сликовних података [14]. Уместо потпуно повезаних слојева, CNN користи конволуционе слојеве у којима се мали филтери (енгл. *kernels*) примењују преко целе слике, откривајући локалне карактеристике попут ивица, облика и текстура. Излаз конволуционог слоја са филтером $\boldsymbol{K}$ над улазом $\boldsymbol{X}$ на позицији (i, j) дат је са:

$$(\boldsymbol{X} * \boldsymbol{K})_{ij} = \sum_{m} \sum_{n} \boldsymbol{X}_{\boldsymbol{i+m, j+n}} \cdot \boldsymbol{K}_{\boldsymbol{m,n}}$$

Хијерархијском применом конволуционих слојева мрежа у плитким слојевима учи једноставне карактеристике (ивице, боје), а у дубљим слојевима комбинује их у сложеније представе. Слојеви сажимања (енгл. *pooling*) смањују просторну резолуцију и чине мрежу отпорном на мале просторне варијације. Ова архитектурна основа лежи у позадини модела за детекцију и сегментацију описаних у потпоглављима 3.4.1 и 3.4.2.

3.4. Модели рачунарског вида за анализу сцене

За формирање структурисане репрезентације сцене потребно је, на основу улазне слике, издвојити присутне објекте, одредити њихове регионе, проценити просторне односе и утврдити релевантне

визуелне атрибуте. Због тога системи визуелног разумевања често комбинују моделе за детекцију објеката, сегментацију инстанци, процену дубине и класификацију атрибута. У наставку су приказани основни принципи модела који припадају овим групама.

3.4.1. Детекција објеката и YOLOv8

Детекција објеката је задатак у коме је потребно локализовати и идентификовати објекте присутне на слици. За разлику од класификације, где се целој слици додељује једна категорија, код детекције је неопходно одредити и положај сваког објекта, најчешће у облику ограничавајућег правоугаоника (енгл. *bounding box*). Савремени модели за детекцију, поред координата региона, враћају и вредност поузданости предвиђања.

YOLOv8 (енгл. *You Only Look Once*) припада породици детектора код којих се локализација и класификација врше у једном пролазу кроз мрежу [15], [16]. Архитектура оваквих модела најчешће садржи део за издвајање карактеристика (енгл. *backbone*), део за њихово обједињавање на више нивоа просторне резолуције (енгл. *neck*) и излазне слојеве који формирају коначне предикције. Једна од карактеристика модела YOLOv8 јесте приступ без унапред дефинисаних оквира (енгл. *anchor-free*), при коме мрежа директно предвиђа положај и димензије објеката [16].

У системима детекције често се примењује поступак потискивања немаксималних детекција (енгл. *Non-Maximum Suppression*, NMS), којим се уклањају вишеструке детекције истог објекта на основу степена преклапања ограничавајућих правоугаоника. Степен преклапања најчешће се мери метриком пресек кроз унију (енгл. *Intersection over Union*, IoU), дефинисаном изразом: $\mathrm{IoU}(A, B) = \frac{|A \cap B|}{|A \cup B|}$

3.4.2. Сегментација инстанци и FastSAM

Сегментација инстанци подразумева задатак издвајања појединачних објеката на нивоу пиксела. Док ограничавајући правоугаоник даје само приближну локализацију објекта, сегментациона маска омогућава прецизније раздвајање објекта од позадине. Потребно је разликовати семантичку сегментацију, код које се пиксели разврставају по класама без раздвајања појединачних инстанци, од сегментације инстанци, код које сваки појединачни објекат добија засебну маску.

FastSAM (енгл. *Fast Segment Anything Model*) је модел намењен сегментацији инстанци, развијен као ефикаснија алтернатива општијим моделима за сегментацију [17]. Заснива се на архитектури прилагођеној брзој сегментацији и користи информацију о положају објекта како би за издвојени регион формирао пикселску маску. На тај начин се за сваки детектовани објекат добија прецизнија репрезентација његовог стварног облика него што је то могуће само на основу ограничавајућег правоугаоника.

Бинарне маске добијене сегментацијом могу се, по потреби, додатно побољшати морфолошким операцијама. Отварање, дефинисано као ерозија праћена дилатацијом, служи за уклањање малих изолованих региона и шума. Затварање, дефинисано као дилатација праћена ерозијом, користи се за попуњавање мањих празнина и прекида унутар маске.

3.4.3. Процена дубине из слике и MiDaS

Процена дубине из једне слике се своди на задатак одређивања релативне дубине пиксела на основу дводимензионалног визуелног улаза. Резултат је мапа дубине у којој вредност сваког пиксела одражава његов положај у простору у односу на камеру. Иако овакви модели не морају да дају апсолутне метричке вредности, релативни односи дубине често су довољни за закључивање о просторном распореду објеката.

MiDaS је модел за монокуларну процену дубине, односно за одређивање релативне дубине пиксела на основу једне слике [18]. Излаз овог модела је мапа дубине, у којој вредност сваког пиксела одражава његов релативни положај у простору у односу на камеру. Посебна предност модела MiDaS огледа се у томе што је развијен тако да обезбеди робусне процене на различитим скуповима података и у различитим доменима. У задацима визуелног резоновања оваква процена је значајна јер омогућава одређивање просторних односа, као што су испред и иза, који се не могу поуздано извести искључиво из дводимензионалног положаја објеката у равни слике.

3.4.4. Екстракција визуелних атрибута и CLIP

Екстракција визуелних атрибута обухвата одређивање карактеристика објеката које су релевантне за опис и резоновање над сценом, као што су боја, облик, материјал и величина. У општем случају, овај задатак може се посматрати као класификација региона слике у односу на унапред дефинисан скуп вредности атрибута.

CLIP је мултимодални модел који учи заједнички простор репрезентација слика и текстуалних описа путем контрастивног учења [19]. Визуелни и текстуални кодер (енгл. *encoder*) кодирају своје улазе у векторе исте димензије. Током тренинга минимизује се контрастивна функција губитка која приближава векторе одговарајућих парова слика-текст, а удаљује неодговарајуће парове. Захваљујући таквој организацији, могуће је поредити визуелну репрезентацију издвојеног региона слике са текстуалним описима кандидатних вредности атрибута и одабрати кандидата са највећом косинусном сличношћу:

$$\mathrm{sim}(u, v) = \frac{u \cdot v}{|u|\,|v|}$$

Овакав приступ омогућава класификацију без додатног обучавања, односно одређивање атрибута без посебног обучавања модела за сваки појединачни подзадатак (енгл. *zero-shot*).

3.5. Трансформерски модели за обраду природног језика и T5

За аутоматску обраду питања на природном језику у савременим системима најчешће се користе трансформерски модели [20]. Њихова предност огледа се у способности да моделују зависности између елемената секвенце без ослањања на класичне рекурентне механизме, што их чини погодним за задатке разумевања и генерисања текста.

3.5.1. Трансформерска архитектура и механизам пажње

Трансформерска архитектура заснива се на механизму пажње (енгл. *Attention mechanism*), који омогућава моделу да приликом обраде сваког елемента секвенце узме у обзир и остале релевантне елементе [20]. Кључна операција је *scaled dot-product attention*, дефинисана над матрицама упита Q, кључева K и вредности V:

$$\text{Attention}(Q, K, V) = \text{softmax!}\left(\frac{QK^{\top}}{\sqrt{d_k}}\right)V$$

Где је d_k димензија кључева која служи за скалирање ради нумеричке стабилности. Оваква операција омогућава да сваки елемент секвенце пондерисано агрегира информације из свих осталих елемената, а паралелна природа матричног множења омогућава ефикаснији тренинг у односу на рекурентне мреже.

Модели за пресликавање секвенце у секвенцу (енгл. ***sequence-to-sequence***) засновани на трансформерима најчешће су организовани у два дела: **кодер** (енгл. *encoder*) и **декодер** (енгл. *decoder*). Кодер обрађује улазну секвенцу и формира њену контекстуалну репрезентацију, док декодер на основу те репрезентације поступно генерише излазну секвенцу. При томе декодер, поред већ генерисаног дела излаза, користи и информације из улазне секвенце путем механизма унакрсне пажње (енгл. *cross-attention*).

На тај начин модел формира везу између улазне и излазне секвенце, што ову архитектуру чини погодном за задатке пресликавања природног језика у формални запис.

3.5.2. T5 и семантичко парсирање

T5 (енгл. *Text-to-Text Transfer Transformer*) представља трансформерски модел типа кодер-декодер, код кога се различити задаци обраде природног језика формулишу као пресликавање улазног текста у излазни текст [21]. Оваква формулација омогућава примену истог модела на различите задатке, укључујући превођење, сумирање, класификацију и генерисање формалних записа. У том смислу, T5 припада класи модела погодних за задатке семантичког парсирања, у којима је потребно природнојезички улаз пресликати у структурисану или формалну репрезентацију.

3.5.3. Велики језички модели

Поред кодер-декодер модела попут T5, у савременој обради природног језика широко се користе и ауторегресивни декодерски трансформери, познати као велики језички модели (енгл. *Large Language Models*, LLM). Ови модели, међу којима се истиче породица LLaMA, генеришу текст токен по токен, при чему сваки нови токен зависи од свих претходно генерисаних [22]. Обучени на веома великим количинама текстуалних података, они поседују широко знање о структури природног и формалног језика.

Кључна особина LLM-а релевантна за практичну употребу јесте могућност рада у режиму *zero-shot*: задатак се описује текстуалним промптом у самом улазу, без икаквог додатног тренирања на доменским примерима [23]. Иако такав приступ не може да достигне ниво специјализованог модела фино подешеног за конкретан задатак, омогућава брзу примену и служи као природна упоредна тачка у евалуацији.

3.5.4. Учење поткрепљивањем и алгоритам REINFORCE

Учење поткрепљивањем (енгл. *Reinforcement Learning*, RL) је парадигма машинског учења у којој агент учи да доноси одлуке кроз интеракцију са окружењем. У сваком кораку агент бира акцију у складу са својом политиком (енгл. *policy*) и добија сигнал награде (енгл. *reward*) на основу исхода. Циљ обучавања је пронаћи политику која максимизује очекивану кумулативну награду.

У контексту генерисања секвенци, политика агента одговара расподели вероватноћа коју модел придружује могућим излазним токенима, при чему се читава генерисана секвенца може посматрати као једна акција. Алгоритам REINFORCE [24] је метод директне оптимизације политике градијентним успоном, при чему се градијент циљне функције процењује на основу узоркованих секвенци и придружених награда:

$$\nabla_\theta J(\theta) \approx (r - b)\nabla_\theta \log \pi_\theta(y|x)$$

где је y генерисана секвенца за улаз x, r добијена награда, b базна вредност за смањење варијансе, а $\pi_{\theta(y|x)}$ вероватноћа коју модел придружује секвенци. Одузимање базне вредности b не мења очекивану вредност градијента, али значајно смањује варијансу процене и тиме стабилизује процес обучавања.

При примени REINFORCE алгоритма на велике претрениране моделе јавља се ризик од катастрофалног заборављања, односно брзог губитка знања стеченог током претренирања. Ради ублажавања овог ефекта, циљној функцији додаје се KL дивергенција између тренутне политике π_θ и референтне расподеле π_{ref}:

$$J'(\theta) = J(\theta) - \beta \cdot D_{KL}\left(\pi_\theta \parallel \pi_{ref}\right)$$

Коефицијент β одређује јачину регуларизације. Овај приступ омогућава да се модел прилагоди новом задатку без значајног одступања од иницијалне расподеле, чиме се претходно стечено знање задржава.

3.6. Доменски специфични језик и симболичко извршавање

У задацима који захтевају више узастопних корака закључивања, корисно је да се поступак резоновања представи у формалном облику. У том контексту важну улогу имају доменски специфични језици, који омогућавају да се сложени задаци сведу на низ јасно дефинисаних операција.

Доменски специфични језик (енгл. *Domain-Specific Language*, DSL) је формални језик намењен опису проблема у оквиру уско дефинисаног домена. За разлику од природног језика, који је флексибилан и често двосмислен, DSL омогућава прецизан и једнозначан запис поступка који треба извршити.

Симболичко извршавање подразумева примену тако дефинисаних операција над структурисаном репрезентацијом података. На тај начин сложен поступак закључивања може се представити као композиција више једноставнијих корака, што омогућава јаснији и интерпретабилнији ток резоновања.

4. МЕТОДОЛОГИЈА

У овом поглављу описана је методологија развијеног неуросимболичког система за визуелно одговарање на питања над сликама. Улаз у систем чини пар који се састоји од слике и питања формулисаног на природном језику, док је излаз одговор у текстуалном облику. У зависности од типа питања, одговор може бити број, потврдан или одречан исказ, или вредност одговарајућег атрибута.

Систем је организован као скуп међусобно повезаних, али функционално раздвојених компоненти. Перцептивни део система из улазне слике формира структурисану репрезентацију сцене, док део за резоновање питање на природном језику преводи у симболички програм и извршава га над добијеном репрезентацијом. Оваква подела омогућава да се одвојено анализира допринос перцепције и допринос резоновања укупној тачности система.

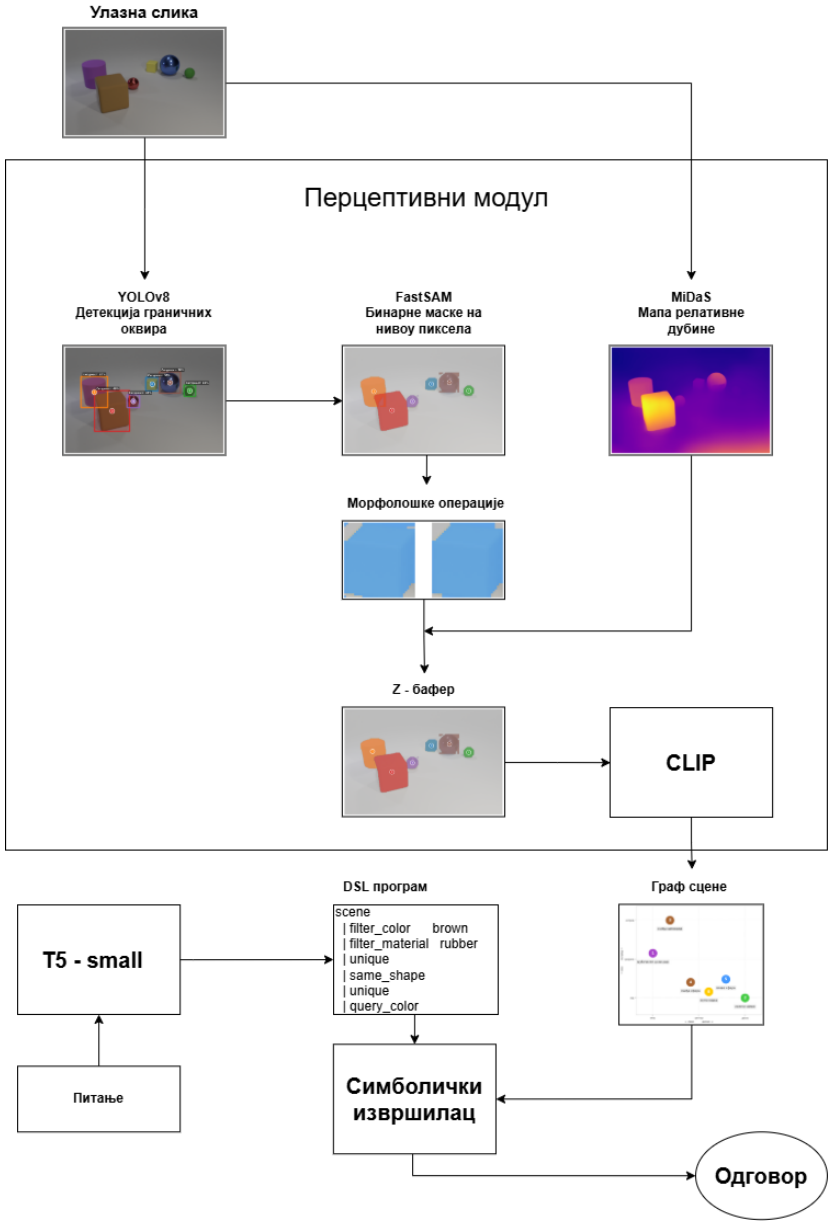
У наставку поглавља најпре је описана архитектура система на високом нивоу апстракције, а затим су разрађени појединачни модули: детекција и сегментација објеката, процена дубине и резолуција преклапања маски, екстракција атрибута и просторних односа, изградња графа сцене, превођење питања у DSL програм и симболичко извршавање. На крају су наведени коришћени алати и софтверске библиотеке.

4.1. Архитектура система

Архитектура система заснива се на јасном раздвајању перцепције и резоновања. Интерфејс између ова два дела представља граф сцене, односно структурисана JSON репрезентација детектованих објеката, њихових атрибута и међусобних просторних односа. Захваљујући таквој организацији, могуће је засебно мерити квалитет визуелне анализе сцене и квалитет превођења питања у симболички

програм, што није једноставно остварив код потпуно неуронских приступа.

На слици 4.1 приказан је ток података кроз систем. Улазна слика се прослеђује перцептивном модулу, који обједињује више модела рачунарског вида. Модел YOLOv8 врши детекцију објеката и одређује њихове граничне оквире, FastSAM формира бинарне маске на нивоу пиксела, MiDaS производи мапу релативне дубине, док се CLIP користи за класификацију визуелних атрибута издвојених објеката. Резултати ових модула интегришу се у граф сцене. Паралелно с тим, питање на природном језику прослеђује се моделу T5-small, који генерише DSL програм. Коначно, симболички извршилац извршава програм над графом сцене и формира одговор.



Слика 4.1. Архитектура предложеног неуросимболичког система за визуелно одговарање на питања. Перцептивни модул из улазне слике формира граф сцене, док модел T5-small питање преводи у DSL програм који се затим симболички извршава над графом сцене.

4.2. Детекција и сегментација објеката

Циљ овог модула је издвајање свих присутних објеката из улазне слике у облику граничних оквира и бинарних маски. Улаз у модул је RGB слика произвољних димензија, док је излаз листа детекција, при чему свака детекција садржи гранични оквир, оцену поузданости и, када је доступна, одговарајућу бинарну маску. У фази претпроцесирања слика се учитава у RGB формату, а за поједине кораке издвајају се локални исечци дефинисани граничним оквирима детекција. Додатна аугментација слика није примењена, будући да се перцептивни модул ослања на претходно обучене моделе.

4.2.1. Хибридни детектор

За детекцију објеката примењен је хибридни приступ који комбинује YOLOv8 детекцију и FastSAM сегментацију у режиму „сегментирај све" (енгл. segment everything). YOLOv8m је одабран због доброг односа брзине и тачности. Полазећи од тежина претренираних на скупу COCO, модел је додатно обучен на 35.000 CLEVR тренинг слика са јединственом категоријом детекције, чиме је прилагођен карактеристикама синтетичких CLEVR сцена; на тај начин смањен је број лажно позитивних детекција и побољшана прецизност граничних оквира у поређењу са директном применом претренираног модела. Разлог за комбинацију са FastSAM-ом лежи у компензацији слабости појединачних приступа: YOLOv8m може пропустити објекте код делимичних преклапања или необичних просторних конфигурација, док FastSAM, без ослањања на класну ознаку, у режиму „сегментирај све" поуздано издваја видљиве регионе и тако допуњује скуп детекција.

На Слици 4.2. приказан је пример резултата хибридне детекције, са поређењем оригиналне слике и коначног скупа детектованих објеката добијених комбиновањем YOLOv8 и FastSAM модела.

Поступак хибридне детекције одвија се у више корака. Најпре се примењује филтер површине, тако да се одбацују све детекције чији гранични оквир заузима мање од 0,1% или више од 40% укупне површине слике. На тај начин уклањају се ситне шумне детекције, као

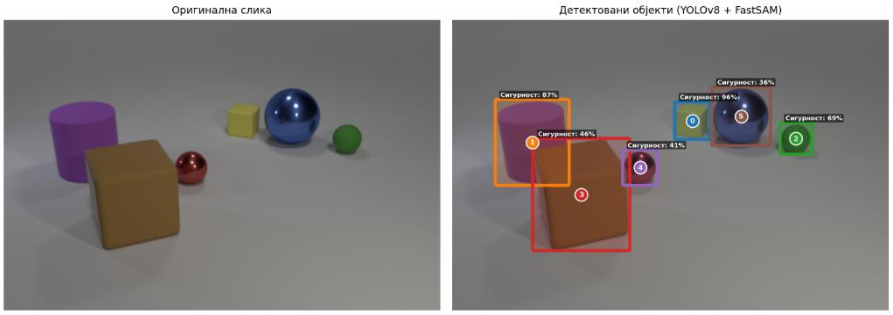
и лажно велики региони који обухватају позадину или већи део сцене. Након тога покрећу се оба модела: YOLOv8m са прагом поузданости 0,1, који је намерно постављен ниско ради већег опозива, и FastSAM са параметрима `conf` и `iou`, постављеним на 0,4 и 0,9. При томе параметар conf представља минималну прихватљиву поузданост предикције, док iou одређује праг преклапања који се користи при уклањању сувишних предикција.

Излази два модела затим се обједињују на основу мере преклапања *Intersection over Union* (IoU). За сваки гранични оквир добијен YOLO моделом проналази се FastSAM маска са највећом IoU вредношћу. Ако је та вредност већа или једнака 0,3, детекције се сматрају подударним. Оцена такве детекције одређује се као линеарна комбинација поузданости оба модела:

$$\text{оцена} = 0{,}7 \cdot \text{поузданост}_{\text{YOLO}} + 0{,}3 \cdot \text{поузданост}_{\text{FastSAM}}$$

Већи коефицијент додељен је YOLO моделу јер његова оцена носи и семантичку информацију о класи, док FastSAM пре свега обезбеђује квалитетну просторну сегментацију.

FastSAM маске које немају одговарајући YOLO пар укључују се као самосталне детекције само ако је њихова поузданост најмање 0,7 и ако се значајно не преклапају са већ прихваћеним детекцијама, односно ако је IoU мањи од 0,2 са свим прихваћеним елементима. На тај начин у сцену се укључују и објекти које класификациони детектор није уочио.



Слика 4.2. Пример резултата хибридне детекције.

4.2.2. Сегментација по граничном оквиру

Иако хибридни детектор већ може да произведе маску за сваки детектовани објекат, такве маске нису увек довољно прецизне, јер FastSAM у режиму „сегментирај све“ анализира целу слику и може делимично спојити суседне регионе. Због тога се за сваки прихваћени гранични оквир покреће додатни корак прецизне сегментације, у коме се FastSAM примењује над издвојеним исечком слике.

Поступак се одвија тако што се најпре из слике издвоји регион који одговара граничном оквиру, уз мало додатно оивичавање. Тај исечак се затим прослеђује FastSAM моделу са параметрима `imgsz = 512`, `conf = 0.4` и `iou = 0.9`, при чему параметар `imgsz` одређује величину слике. Ако модел врати више маски, задржава се маска са највећом површином, јер у уско ограниченом региону она у највећем броју случајева одговара посматраном објекту.

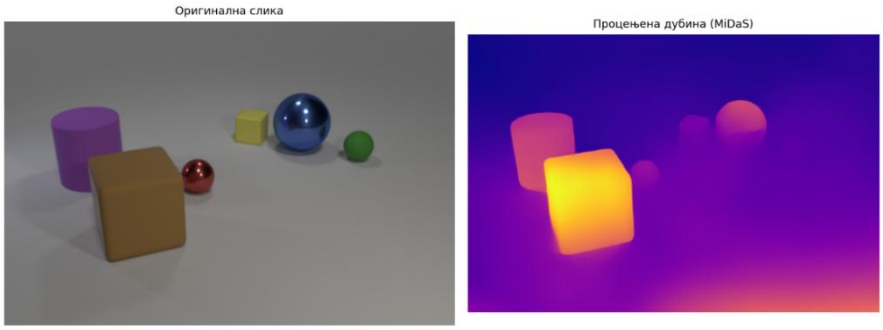
Добијена маска затим пролази кроз морфолошко постпроцесирање. Примењују се две узастопне операције са језгром величине 3×3 пиксела. Отварање, дефинисано као ерозија праћена дилатацијом, користи се за уклањање ситних изолованих региона и шума. Затварање, дефинисано као дилатација праћена ерозијом, служи за попуњавање мањих празнина и прекида унутар маске. Након ових корака, очишћена маска пресликава се назад у координатни систем целе слике применом офсета граничног оквира.

4.3. Процена дубине и резолуција преклапања маски

Овај модул има два задатка. Први је да сваком детектованом објекту придружи процену дубине у сцени, а други да разреши конфликте у случајевима када се маске више објеката преклапају у равни слике.

4.3.1. Монокуларна процена дубине

За процену релативне дубине примењен је модел MiDaS у варијанти MiDaS_small. Ова варијанта одабрана је због повољног односа робусности и рачунарске ефикасности, што је важно за његову интеграцију у вишестепени перцептивни модул. Улаз у модел је RGB слика, а излаз мапа дубине истих димензија, при чему већа нумеричка вредност одговара мањој удаљености од камере, односно ближем плану. Овакав запис познат је као инверзна дубина и то је стандардна конвенција MiDaS модела. Пошто су за даље резоновање довољни релативни, а не метрички односи дубине, овај излаз је адекватан за потребе система. На Слици 4.3. приказан је пример излазне мапе дубине добијене применом модела.



Слика 4.3. Пример процене релативне дубине применом модела MiDaS. Лево је приказана оригинална улазна слика, а десно одговарајућа мапа дубине, при чему светлије вредности означавају ближе, а тамније даље регионе.

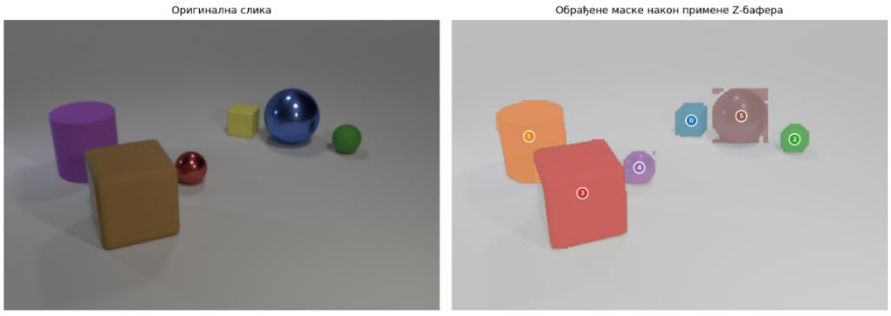
Након добијања мапе дубине, свакој детекцији придружују се три статистичке вредности: средња, минимална и максимална дубина у региону објекта. Ако је доступна бинарна маска, статистике се рачунају искључиво на основу пиксела који припадају маски. У супротном се користи цела површина граничног оквира. Оваква организација обезбеђује да вредности дубине одражавају положај самог објекта, а не позадине која би могла бити присутна у оквиру.

4.3.2. Резолуција преклапања маски применом Z-бафера

Када се маске више објеката преклапају, исти пиксел може бити додељен већем броју детекција. Такав конфликт разрешава се применом алгоритма Z-бафера, чија је улога да сваком пикселу додели припадност само једном објекту, у складу са процењеном дубином. Пример резултата након примене овог поступка приказан је на Слици 4.4.

Детекције се најпре сортирају по средњој вредности дубине. Затим се одржава булова матрица `occupied`, истих димензија као и улазна слика, која бележи који су пиксели већ заузети. За сваку детекцију израчунава се нова маска као пресек постојеће маске и логичке негације матрице `occupied`. Ако је тако добијена маска празна, детекција се сматра потпуно заклоњеном и искључује се из даљег процесирања. У супротном, нова маска постаје важећа маска детекције, а матрица `occupied` ажурира се унијом са том маском.

Резултат овог поступка је скуп непреклапајућих маски у коме ближи објекти имају приоритет над даљим. Овај корак је значајан јер се у супротном током издвајања атрибута унутар региона објекта могу појавити пиксели других објеката, што би утицало на квалитет касније класификације.



Слика 4.4. Резултат сегментације након примене модела FastSAM и резолуције преклапања маски применом алгоритма Z-бафера. Лево је приказана оригинална улазна слика, а десно обрађене маске објеката које се не преклапају.

4.4. Екстракција атрибута и просторних односа

Циљ овог модула је да за сваки детектовани објекат одреди дискретне визуелне атрибуте и израчуна међусобне просторне односе. Разматрани атрибути су боја, облик, материјал и величина, док се просторни односи своде на четири релације: лево, десно, испред и иза.

4.4.1. Екстракција атрибута применом CLIP-а

За класификацију боје, облика и материјала коришћен је CLIP у режиму класификације без додатног обучавања. Овај модел је изабран јер омогућава поређење визуелних исечака са текстуалним описима вредности атрибута без тренирања засебног класификатора за сваки атрибут. Основна идеја овог приступа јесте да модел пројектује и слике и текстуалне описе у заједнички простор репрезентација, након чега се атрибут одређује избором текстуалног описа са највећом косинусном сличношћу у односу на посматрани исечак објекта.

За сваки атрибут дефинисан је затворен скуп кандидатних вредности. За сваку вредност конструисана су по три текстуална промпта, на пример: `*a red object*`, `*a red colored thing*` и `*something red*`. Текстуалне репрезентације свих промптова израчунавају се приликом иницијализације и кеширају, тако да се у фази примене модела кодира само слика издвојеног региона. За сваку вредност атрибута коначна текстуална репрезентација добија се усредњавањем репрезентација свих одговарајућих промптова. Предикција се затим одређује као она вредност атрибута чија је текстуална репрезентација најсличнија визуелној репрезентацији посматраног објекта, мерено косинусном сличношћу.

За класификацију величине није коришћен CLIP, јер изолован исечак објекта не садржи довољно контекста за процену релативне величине. Уместо тога примењена је хеуристика заснована на површини граничног оквира. Ако је површина оквира већа од медијане површина свих детекција у истој сцени, објекат се означава као велики, у супротном се означава као мали.

4.4.2. Израчунавање просторних односа

Просторни односи израчунавају се парно за сваки уређени пар детектованих објеката. Разматрају се четири релације: лево, десно, испред и иза.

Односи лево и десно израчунавају се на основу x-координата центара граничних оквира. Нормализоване координате добијају се дељењем са ширином слике W, тако да важи

$$x_i = \frac{c_{x_i}}{W}, \qquad x_j = \frac{c_{x_j}}{W}$$

при чему c_{x_i} и c_{x_j}означавају хоризонталне координате центара објеката i и j.За сваки пар објеката рачуна се разлика $\Delta_x = x_j - x_i$. Ако је $\Delta_x > \tau_x$, закључује се да је објекат j десно од објекта Ако је $\Delta_x < -\tau_x$, закључује се да је објекат j лево од i. Вредности Δ_x блиске нули не доводе до додељивања односа. У имплементацији је коришћен праг $\tau_x = 0.07$.

Односи испред и иза одређују се на основу нормализованих вредности дубине. Нека d_i и d_j означавају средње вредности дубине објеката i и j. Пошто MiDaS даје инверзну дубину, већа вредност одговара ближем објекту. За сваки пар објеката рачуна се разлика $\Delta_d = d_j - d_i$. Ако је $\Delta_d > \tau_d$, закључује се да је објекат jиспред објекта i. Ако је $\Delta_d < -\tau_d$, закључује се да је објекат j иза објекта i. Вредности Δ_d блиске нули не доводе до додељивања односа. У имплементацији је коришћен праг $\tau_d = 0.13$.

4.5. Изградња графа сцене

Граф сцене чини централни интерфејс система, односно структурисани излаз перцептивног модула и директни улаз у симболички извршилац. Изградњу графа сцене координише класа `SceneGraphBuilder`, која позива све компоненте перцептивног модула у унапред дефинисаном редоследу. Улаз у овај процес је RGB

слика, а излаз JSON структура која садржи листу објеката, њихове атрибуте, координатне информације и просторне односе.

Редослед обраде је следећи. Најпре се примењује хибридни детектор, који враћа листу детекција са граничним оквирима и грубим маскама. Затим се покреће прецизна сегментација по граничном оквиру, чиме се добијају рафинисане бинарне маске. После тога се израчунава мапа дубине и дубинске статистике се придружују свакој детекцији. У наредном кораку примењује се алгоритам резолуције преклапања маски. Затим се врши екстракција атрибута и рачунање просторних односа. Резултат целог поступка је комплетан граф сцене.

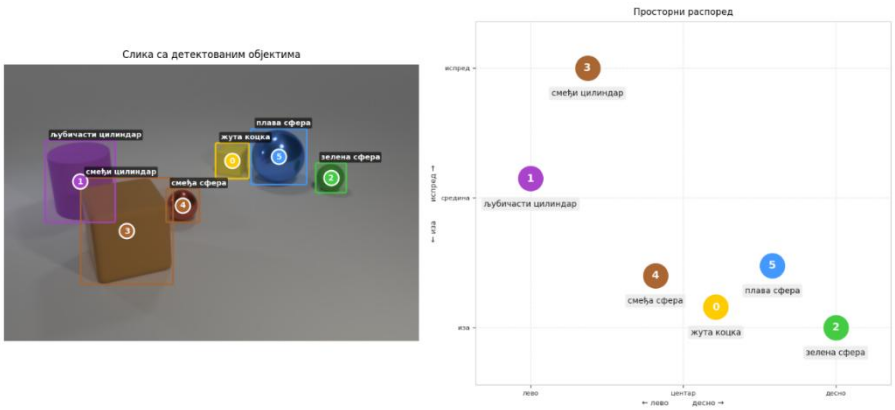
4.5.1. Формат графа сцене

Излаз методе `SceneGraphBuilder.build()` има два основна дела: `objects`, који представља листу детектованих објеката, и `relationships`, који представља речник просторних односа. Сваки објекат садржи атрибуте `color`, `shape`, `material` и `size`, координате граничног оквира `bbox`, као и поље `pixel_coords`, које садржи x и y координату центра објекта и средњу вредност дубине унутар маске.

Поље `relationships` организовано је тако да за сваку релацију постоји листа листа индекса. На пример, `relationships["left"][i]` садржи индексе свих објеката у односу на које је објекат i лево. Ова репрезентација је погодна за симболичко извршавање, јер омогућава директно праћење релација без додатних конверзија

4.5.2. Визуализација графа сцене

Ради анализе и дебаговања имплементиран је и модул за визуализацију графа сцене. Функција `render_scene_graph()` производи двопанелну слику. Леви панел приказује оригиналну слику, док десни панел приказује просторни распоред објеката у нормализованом координатном систему, где x-оса одговара хоризонталном положају, а y-оса дубини. Додатно, функција `compare_scene_graphs()` омогућава упоредни приказ референтног и детектованог графа сцене, што је корисно при анализи грешака перцепцијског модула.



Слика 4.5. Приказ детектованих објеката и њиховог просторног распореда у графу сцене.

4.6. Превођење питања у DSL програм

Циљ овог модула је превођење питања на природном језику у извршив DSL програм. Улаз представља стринг питања, а излаз је структурисани програм у облику листе корака, при чему сваки корак описује једну DSL операцију, њене улазне референце и евентуалне вредносне аргументе.

4.6.1. Типови података и оператори DSL-а

DSL коришћен у овом раду заснован је на функционалном програмском формату из CLEVR скупа података, уз формалну типску спецификацију која је уведена у овом раду ради валидације програма пре извршавања. Сваки оператор производи вредност тачно одређеног типа, а улазни типови морају одговарати очекиваном потпису. Уведена су четири основна типа података: `ObjectSet`, `Integer`, `Bool` и `Attribute`. Тип `ObjectSet` представља скуп референци на објекте графа сцене и чини главни ток резоновања. Тип `Integer` користи се за бројевне резултате, `Bool` за логичке исказе, а `Attribute` за вредности атрибута као што су боја, облик, материјал или величина.

Скуп допуштених вредносних аргумената дефинисан је унапред. За боју је то скуп од осам вредности, за облик три, за величину две, за материјал две, а за просторне релације четири вредности. Оператори су организовани у више функционалних категорија: операције формирања сцене, филтрирања, релационе операције, скупне операције, упити над атрибутима, бројачке и логичке операције, као и операције поређења и тражења истих атрибута.

Унутрашња репрезентација програма реализована је као листа речника, где сваки корак садржи назив оператора, листу индекса претходних корака чији се резултат користи и евентуалне вредносне аргументе. На овај начин програм представља усмерени ациклични граф, који може бити линеаран или разгранат, у зависности од структуре питања.

4.6.2. Линеаризација програма за тренирање

Да би T5 модел могао да генерише DSL програме, потребно је структурисану репрезентацију програма превести у текстуалну секвенцу. У ту сврху примењена је линеаризација заснована на раздвајачу `|`, при чему су референце на претходне кораке експлицитно наведене само онда када нису имплицитно задате редоследом.

Ако операција узима искључиво излаз непосредно претходног корака, референца се изоставља. Ако се користи излаз неког ранијег корака, његов индекс наводи се иза двотачке. Код бинарних оператора наводе се оба индекса, раздвојена зарезом. На овај начин сложени програми могу се представити као једна текстуална секвенца погодна за обучавање модела типа кодер-декодер.

Пре употребе у процесу обучавања, над свим програмима извршена је провера кружне конверзије: сваки програм је најпре серијализован, а затим поново десеријализован, уз проверу да ли је добијена структура идентична полазној. На тај начин осигурано је да линеаризована форма не губи информацију садржану у оригиналном програму.

4.6.3. Додатно обучавање T5-small модела

За превођење питања у DSL програме коришћен је модел T5-small, заснован на архитектури кодер-декодер. Модел је додатно обучен на паровима питање-програм из CLEVR корпуса, применом унакрсне ентропије над токенима излазне секвенце. Тако добијени модел служи као полазна тачка за даље прилагођавање на скупу CLEVR-Humans применом учења поткрепљивањем (видети потпоглавље 3.5.4). Детаљи експерименталне поставке оба корака обучавања, као и евалуације, приказани су у поглављу 5.

4.6.4. Инференца и валидација програма

Приликом генерисања програма T5 модел производи више кандидатних секвенци применом снопног декодирања (енгл. *beam search*) са ширином снопа 5. Свака добијена текстуална секвенца затим се десеријализује у унутрашњу DSL репрезентацију и прослеђује валидатору.

Валидатор проверава три услова. Најпре се испитује структурна исправност програма, односно да ли постоје недозвољене референце, негативни индекси или празан програм. Затим се проверава исправност

типова, односно да ли оператори добијају улазне вредности очекиваних типова. На крају се проверава исправност вредносних аргумената, односно да ли наведене боје, облици, материјали и релације припадају допуштеним скуповима. Прихвата се први кандидат који прође све провере. Ако ниједан кандидат није исправан, питање се бележи као неуспешно обрађено.

4.7. Симболичко извршавање

Симболички извршилац, реализован у класи `Executor`, извршава DSL програм над графом сцене на потпуно детерминистички начин, без иједне неуронске компоненте. Улаз су DSL програм и граф сцене, а излаз представља коначни одговор, који може бити број, вредност атрибута или одговор типа „*yes*“/„*no*“.

Извршилац одржава листу међурезултата у коју се уписује резултат сваког корака програма. Сваки наредни корак приступа претходним резултатима преко индекса наведених у пољу `inputs`, док се вредносни аргументи преузимају из поља `value_inputs` или `side_inputs`. На овај начин сваки оператор добија тачно оне улазне податке који су му потребни.

Посебно важан оператор је `unique`, који проверава да ли текући скуп објеката садржи тачно један елемент. Ако је скуп празан или садржи више објеката, извршилац пријављује грешку. У пракси је ово чест узрок неуспелог извршавања при раду над детектованим графом сцене, јер грешка у атрибутској класификацији може довести до тога да услов не задовољи ниједан објекат или да га задовољи више њих.

Ако је коначни резултат логичка вредност, она се аутоматски преводи у текстуални одговор `*yes*` или `*no*`, у складу са форматом одговора у CLEVR скупу.

Кључна особина овог извршиоца јесте потпуна детерминистичност. Ако су програм и граф сцене исправни, резултат извршавања је једнозначно одређен. Управо зато симболички извршилац представља погодну основу за јасно разграничење грешака

насталих у фази перцепције и грешака насталих у фази превођења питања, што је посебно значајно у каснијој евалуацији система.

4.8. Коришћени алати

Систем је имплементиран у програмском језику Python 3.10. За детекцију објеката коришћена је библиотека Ultralytics са тежинама модела YOLOv8m додатно обученим на CLEVR подацима, док је за сегментацију инстанци коришћен модел FastSAM-s доступан кроз исти програмски интерфејс. Монокуларна процена дубине реализована је применом модела MiDaS_small из репозиторијума intel-isl/MiDaS, учитаног преко torch.hub [25]. За класификацију атрибута примењен је CLIP у варијанти ViT-B/32. Морфолошке операције над бинарним маскама реализоване су помоћу OpenCV библиотеке [26].

За додатно обучавање T5-small модела [21] коришћена је библиотека transformers компаније Hugging Face [27]. Обучавање на CLEVR корпусу извршено је у Google Colab окружењу уз GPU акцелерацију [28], док је фаза учења поткрепљивањем на скупу CLEVR-Humans изведена на платформи Kaggle уз T4 GPU акцелератор. Симболички извршилац, DSL валидатор и евалуациони оквир реализовани су у чистом Python-у, уз употребу стандардних модула као што су json и itertools.

5. ЕКСПЕРИМЕНТИ

У овом поглављу описана је експериментална поставка коришћена за вредновање предложеног система. Најпре су приказани скупови података и заједничка евалуациона поставка, а затим и појединачни експерименти: додатно обучавање T5-small модела за превођење питања у DSL, испитивање генерализације на дистрибуцијски различитим скуповима и евалуација комплетног система са детектованим графом сцене. Резултати ових експеримената приказани су у поглављу 6.

5.1. Скупови података

У свим експериментима коришћени су скупови података из CLEVR породице. Иако имају заједничку основу у виду сцена, питања и одговора, разликују се по врсти језичког и визуелног одступања у односу на податке коришћене за обучавање, због чега су погодни за испитивање генерализације и анализу различитих извора грешке у систему.

Сви скупови података коришћени у овом раду преузети су у изворном формату и прилагођени за уједначену обраду у оквиру експеримената. Детаљи припреме и специфичности конверзије наведени су у опису сваког скупа појединачно.

5.1.1. CLEVR

CLEVR (*Compositional Language and Elementary Visual Reasoning*) [2] је синтетички скуп података намењен вредновању вишекорачног визуелног резоновања. Слике су генерисане у контролисаном тродимензионалном окружењу и приказују сцене које садрже између 3 и 10 објеката. Записане су у PNG формату, резолуције 480 × 320 пиксела, а просечан број објеката по сцени износи 6,5.

Објекти не припадају ширем скупу семантичких категорија, већ су дати као једноставна геометријска тела. Конкретно, у сценама се јављају три основна облика објеката: коцка, сфера и цилиндар. Сваки објекат описан је атрибутима боје, облика, материјала и величине, док је свако питање праћено тачним одговором и програмским записом који описује поступак долажења до одговора.

У оквиру овог рада CLEVR има централну улогу. Његов тренинг скуп који обухвата 70.000 слика и 699.989 питања, коришћен је за додатно обучавање T5-small модела за превођење питања у DSL програме, док је валидациони скуп, са 15.000 слика и 149.991 питања, коришћен за евалуацију модула за превођење питања на природном језику у DSL формат, као и за евалуацију комплетног система у току са детектованим графом сцене.

Оригинални скуп података је организован кроз засебне фајлове за питања, сцене и слике. За потребе овог рада ови извори су обједињени у јединствени JSONL формат, тако да сваки запис садржи све информације неопходне за обучавање и евалуацију. При томе садржај питања, одговора и програма није мењан, већ су у један запис спојени питање, одговор, програм, путања до слике и одговарајући граф сцене. Основна поља овако формираног записа приказана су у Табели 5.1.

Поље	**Тип**	**Опис**
`question_id`	`string`	Јединствени идентификатор питања
`question`	`string`	текст питања
`answer`	`string`	тачан одговор
`program`	`object`	програмски запис питања
`image_path`	`string`	путања до одговарајуће слике
`image_id`	`string`	идентификатор слике
`scene_graph`	`object`	структурисан опис сцене

Табела 5.1. Поља конвертованог CLEVR записа.

Објекти у CLEVR сценама описани су атрибутима боје, облика, материјала и величине. Могуће вредности ових атрибута приказане су у Табели 5.2.

Атрибут	Могуће вредности
Боја	*red, blue, green, yellow, cyan, purple, brown, gray*
Облик	*cube, sphere, cylinder*
Материјал	*metal, rubber*
Величина	*large, small*

Табела 5.2. Атрибути објеката у CLEVR скупу.

5.1.2. CLEVR-CoGenT

CLEVR-CoGenT (*Compositional Generalization Test*) [2] представља варијанту CLEVR скупа конструисану тако да испитује генерализацију на неуобичајеним комбинацијама атрибута. У односу на оригинални CLEVR, граматика питања, формат одговора и програмски запис остају непромењени, док се мења расподела комбинација боја и облика у сценама.

У оквиру овог рада коришћен је CoGenT val B, и то искључиво за евалуацију. Поступак припреме података идентичан је поступку примењеном над CLEVR скупом: питања, сцене и слике обједињени су у јединствени JSONL формат, без измене садржаја питања, одговора и програма.

У евалуацији је коришћено 5.000 питања из CoGenT valB скупа.

5.1.3. CLEVR-Humans

CLEVR-Humans [5] је скуп у коме су питања над CLEVR сценама формулисали људи, а не шаблонски генератор. Због чега се у њему јављају природније језичке конструкције, разговорнији стил, синоними и граматичке неправилности.

У овом раду CLEVR-Humans коришћен је за испитивање генерализације модула за превођење питања у DSL програме на питањима која одступају од шаблонског језика CLEVR тренинг скупа. Код овог скупа поље `program` остављено је празно, јер изворни скуп не садржи програмске анотације. Пошто су сцене исте као у CLEVR валидационом скупу, графови сцена преузети су из одговарајућих CLEVR анотација и затим повезани са питањима у јединственом JSONL запису.

У евалуацији је коришћен цео CLEVR-Humans валидациони скуп, који садржи 7.202 питања над 4.000 слика.

5.1.4. Сумарни преглед скупова података

Ради лакшег поређења скупова података, у Табели 5.3 дате су основне статистичке карактеристике питања, програмских записа и типова одговора за скупове коришћене у експериментима.

Скуп	**Просечна дужина питања**	**Просечна дужина DSL програма**	**Одговори тачно/нетачно**	**Целобројни одговори**	**Атрибутски одговори**
CLEVR	18,3 речи	11,1 корака	41,1%	23,8%	35,1%
CoGenT	18,5 речи	11,3 корака	39,7%	24,3%	36,0%
CLEVR-Humans	8,4 речи	не поседује	29,6%	31,0%	39,4%

Табела 5.3. Основне статистичке карактеристике скупова података.

Као што се види из Табеле 5.3, CLEVR и CLEVR-CoGenT деле исту структуру питања и програмских записа, а разликују се само у расподели комбинација атрибута, док CLEVR-Humans јасно одступа краћим и мање шаблонским питањима, што га чини погодним за испитивање генерализације на природнији језик.

5.2. Евалуациона поставка

У овом потпоглављу описан је начин на који је вреднован предложени систем. Најпре су представљени токови евалуације, затим начин формирања евалуационих подскупова, категоризација питања и мере перформанси, а на крају и поступак атрибуције грешака. Циљ овакве поставке јесте да се јасно раздвоји допринос модула за превођење питања у DSL, симболичког извршавања и перцептивне компоненте у укупним перформансама система.

5.2.1. Токови евалуације

Систем је вреднован у два основна тока, у зависности од тога да ли се симболички извршилац снабдева референтним или аутоматски изграђеним графом сцене.

Референтни ток (енгл. *Ground Truth*, GT ток) користи референтни граф сцене из скупа података. У овом случају улаз у систем чини питање, које се најпре преводи у DSL програм, а затим се програм извршава над референтним графом сцене. На овај начин перцептивна компонента не учествује у евалуацији, па се могу изоловати грешке модула за превођење питања у DSL програм и симболичког извршавања.

Ток са детектованим графом сцене користи граф сцене који је аутоматски изграђен на основу улазне слике. У том случају укупна тачност система зависи и од квалитета излаза перцептивног модула и од исправности превођења питања у DSL програм. Овај ток представља реалистичнију поставку, јер одговара начину на који се систем примењује у пуној конфигурацији.

5.2.2. Формирање евалуационих подскупова

Сви скупови података коришћени су у већ постојећим поделама, без формирања нових подскупова за обучавање и тестирање. За потребе евалуације коришћени су валидациони делови скупова. Како су

појединиекспериментизнатнорачунарскизахтевнијиоддругих,у неким случајевима коришћени су подскупови фиксне величине.

Поставка	Скуп	Обим	Ток
Превођење питања у DSL програме унутар домена	CLEVR val	1.000 питања	Референтни ток
Генерализација на комбинације атрибута	CLEVR-CoGenT valB	5.000 питања	Референтни ток
Генерализација на природни језик	CLEVR-Humans val	7.202 питања	Референтни ток
Комплетан систем са детектованим графом сцене	CLEVR val	10.000 питања	Ток са детектованим графом сцене
Перцептивна компонента	CLEVR val	1.000 слика	Перцептивна евалуација

Табела 5.4. Евалуациони подскупови коришћени у експериментима.

Одабрани обими одражавају компромис између статистичке поузданости и рачунарске захтевности експеримената. Посебно је евалуација у току са детектованим графом сцене захтевнија, јер подразумева изградњу графа сцене за сваку слику.

5.2.3. Категорије питања

Ради детаљније анализе, питања су разврстана у пет категорија. Категоризација је заснована на облику питања и лексичким показатељима који се појављују у тексту. На тај начин омогућено је да се резултати не посматрају само збирно, већ и у зависности од врсте резоновања коју појединопитањезахтева.Преглед категоријапитања дат је у Табели 5.5.

Категорија	Опис
`count`	питања која захтевају пребројавање
`exist`	питања која траже одговор типа да/не о постојању
`query`	питања која траже вредност атрибута
`compare`	питања која захтевају поређење броја, атрибута или односа
`other`	преостала питања која не припадају претходним групама

Табела 5.5. Категорије питања коришћене у евалуацији.

5.2.4. Мере перформанси

Главна мера перформанси система је тачност одговора, дефинисана као

$$\text{Acc} = \frac{1}{N}\sum_{i=1}^{N} 1(\widehat{a_i} = a_i)$$

где је N број питања, a_i тачан одговор, а $\widehat{a_i}$ предвиђени одговор за i-то питање. Поред глобалне тачности, рачуната је и тачност по категоријама питања.

За евалуацију модула за превођење питања у DSL програме коришћене су и две дијагностичке мере. Прва је **стопа валидних програма**, дефинисана као удео питања за која је генерисани програм прошао структуралну, типску и вредносну проверу. Друга је **стопа грешке извршавања**, која мери удео случајева у којима је програм формално валидан, али његово извршавање над графом сцене није успешно.

За директну евалуацију перцептивне компоненте коришћен је и **детекциони одзив**, дефинисан као

$$\text{Recall} = \frac{N_{\text{matched}}}{N_{\text{GT}}}$$

где је N_{GT} број референтних објеката у сцени, а N_{matched} број објеката за које је пронађен одговарајући детектовани пар. Поред тога, за упарене парове објеката посматране су тачности класификације атрибута и тачности просторних релација.

Поред наведених мера, у анализи резултата упоређивани су и исходи у референтном току и у току са детектованим графом сцене, како би се раздвојио утицај перцептивне компоненте од утицаја модула за превођење питања у DSL програме и симболичког извршавања. На тај начин разматрани су случајеви неуспешног генерисања валидног програма, грешке током извршавања валидног програма и нетачног коначног одговора упркос успешном извршавању. Ова подела коришћена је као основа за анализу резултата у поглављу 6.

5.3. Додатно обучавање компонената система

У оквиру предложеног система додатно су обучаване две неуронске компоненте: детектор објеката YOLOv8m, ради унапређења квалитета локализације на синтетичким сценама, и модел T5-small, најпре за превођење питања у DSL програме унутар CLEVR домена, а потом и за прилагођавање ширем језичком домену скупа CLEVR-Humans применом учења поткрепљивањем. У наставку су ова три поступка описана у одвојеним потпоглављима.

5.3.1. Додатно обучавање детектора YOLOv8

Перформансе локализације претренираног YOLOv8m модела на синтетичким CLEVR сценама нису оптималне, будући да се домен COCO слика значајно разликује од визуелних карактеристика овог скупа. Због тога је детектор додатно обучен на CLEVR подацима, са циљем да се смањи број пропуштених објеката и лажно позитивних детекција пре него што се резултати проследе наредним фазама перцептивне обраде.

Као полазна тачка коришћен је модел YOLOv8m са предтренираним тежинама на COCO скупу. За додатно обучавање употребљен је тренинг скуп CLEVR са 35.000 синтетичких слика и припадајућим анотацијама граничних оквира. Детектор је обучаван за јединствену категорију `object`, јер је циљ искључиво унапређење квалитета локализације и смањење броја лажно позитивних и лажно негативних детекција. Семантичку класификацију атрибута преузима CLIP у засебном кораку. Обучавање је спроведено током 15 епоха у Kaggle окружењу уз употребу графичког процесора NVIDIA T4.

Квалитет добијеног детектора оцењен је у оквиру директне евалуације перцептивне компоненте описане у потпоглављу 5.6, мерењем детекционог одзива и прецизности на подскупу CLEVR валидационих слика. Резултати ове евалуације приказани су у потпоглављу 6.3.1.

5.3.2. Додатно обучавање T5-small модела на CLEVR скупу

Прва фаза обучавања T5-small модела има за циљ да модел савлада DSL граматику и њено пресликавање на CLEVR питања. У овој фази користи се стандардно надзирано учење на паровима питање-програм из тренинг скупа.

За обучавање је коришћен CLEVR тренинг скуп, при чему су питања дата као улазне текстуалне секвенце, а одговарајући DSL програми у линеаризованој форми описаној у потпоглављу 4.6.2. као циљни излаз. Као полазни модел коришћен је T5-small, а обучавање је спроведено током три епохе применом AdamW оптимизатора и стандардне унакрсне ентропије над токенима излазне секвенце. Кључни хиперпараметри обучавања приказани су у Табели 5.6.

Параметар	Вредност
Максимална дужина улаза	64 токена
Максимална дужина излаза	128 токена
Број епоха	3
Величина мини-пакета	16 (T4) / 32 (A100)
Стопа учења	5×10^{-4}
Weight decay	**0,01**
Број warmup корака	500
Оптимизатор	AdamW

Табела 5.6. Хиперпараметри додатног обучавања T5-small модела.

Обучавање је спроведено у Google Colab окружењу, уз употребу графичког процесора NVIDIA T4. Међуверзије и финална верзија модела чувани су у Google Drive складишту.

Током обучавања евалуација је вршена на сваких 2.000 корака, на подскупу од 2.000 примера из валидационог скупа, применом декодирања при коме се у сваком кораку бира највероватнији наредни токен (енгл. *greedy decoding*).

Завршна евалуација спроведена је на подскупу од 1.000 питања CLEVR валидационог скупа у референтном току. Програми су генерисани применом снопног декодирања са ширином снопа 5, а прихватан је први кандидат који прође поступак валидације описан у потпоглављу 4.6.4.

5.3.3. Додатно обучавање T5-small применом алгоритма REINFORCE

Друга фаза обучавања T5-small модела има за циљ прилагођавање ширем језичком домену скупа CLEVR-Humans. Пошто овај скуп не садржи програмске анотације, надзирано учење није могуће, па се прибегава учењу поткрепљивањем. Модел сам узоркује

кандидатске програме, а сигнал учења добија из исхода њиховог извршавања над референтним графом сцене.

Као полазна тачка коришћен је T5-small модел добијен у потпоглављу 5.3.2. Пошто CLEVR-Humans скуп не садржи програмске записе, обучавање применом стандардне унакрсне ентропије није изводљиво. Уместо тога, примењен је алгоритам REINFORCE, у сваком кораку обучавања, за дато питање и одговарајући референтни граф сцене, модел узоркује N = 4 DSL програма применом декодирања са температуром T = 1,1. Сваки узоркован програм извршава се над графом сцене и добија сигнал награде: +1,0 ако је добијени одговор тачан, +0,2 ако је програм извршив али одговор нетачан, −0,1 ако дође до грешке при извршавању, и 0,0 ако програм не пролази синтаксичку проверу. REINFORCE ажурира тежине модела у смеру повећавања очекиване суме награда, применом базне линије израчунате као просечна награда узорака у текућем мини-пакету.

Ради спречавања прекомерног одступања модела од полазне тачке, у складу са приступом описаним у потпоглављу 3.5.4 примењена је KL регуларизација са коефицијентом $\beta = 0{,}05$ у односу на замрзнут референтни модел. Обучавање је спроведено у Kaggle окружењу уз употребу графичког процесора NVIDIA T4, на CLEVR-Humans тренинг скупу, са резервисаним подскупом од 500 примера за праћење тачности у току обучавања. Стопа учења износи $8 \cdot 10^{-6}$ уз weight decay 0,01. Резултати евалуације одабране контролне тачке описани су у потпоглављу 6.2.

5.4. Генерализација модула за превођење питања у DSL

У овом експерименту испитивано је у којој мери модул за превођење питања у DSL програме, обучен искључиво на CLEVR питањима, задржава употребљивост на скуповима који одступају од података коришћених за обучавање. Циљ је да се провери осетљивост модела на промене у формулацији питања, комбинацијама атрибута и самом визуелном домену.

За ову проверу коришћен је исти T5-small модел добијен у претходном експерименту, без додатног обучавања. Евалуација је спроведена у референтном току, што значи да је генерисани DSL програм извршаван над референтним графом сцене. На тај начин искључен је утицај перцептивне компоненте, па су резултати одражавали искључиво успешност модула за превођење питања у DSL програме и исправност симболичког извршавања.

Као главна мера посматрана је тачност коначног одговора, односно слагање одговора добијеног извршавањем генерисаног програма са референтним одговором из скупа података. Поред тога, праћене су и стопа валидних програма и стопа грешке извршавања, како би се разликовали случајеви у којима модел не успева да генерише формално исправан програм од случајева у којима је програм исправан, али не доводи до тачног одговора.

Евалуација је спроведена на два скупа података која уводе различите типове одступања у односу на CLEVR: CLEVR-CoGenT испитује генерализацију на неуобичајене комбинације атрибута, а CLEVR-Humans на природнији и мање шаблонски језик. У евалуацији је коришћено 5.000 питања из CLEVR-CoGenT valB скупа и 7.202 питања из CLEVR-Humans валидационог скупа.

5.5. Евалуација система са детектованим графом сцене

У овом експерименту вреднован је комплетан систем у поставци у којој граф сцене није референтан, већ се аутоматски изграђује на основу улазне слике применом перцептивне компоненте описане у поглављу 4. Оваква поставка представља најпотпунији вид евалуације, јер обухвата грешке свих кључних фаза система: детекције, сегментације, процене дубине, класификације атрибута и превођења питања у DSL програме.

Евалуација је спроведена у току са детектованим графом сцене, при чему је за свако питање најпре изграђен граф сцене на основу

одговарајуће слике, затим је питање преведено у DSL програм, а добијени програм је извршен над тако формираним графом. Као главна мера посматрана је тачност коначног одговора у односу на референтни одговор из скупа података, док су као допунске мере праћене стопа валидних програма и стопа грешке извршавања. На тај начин било је могуће истовремено вредновати и крајњи учинак система и поузданост његових појединачних фаза.

Евалуација је спроведена на подскупу од 10.000 питања из CLEVR валидационог скупа, формираном као првих 10.000 конвертованих JSONL записа. Ова питања односе се на 1.000 различитих слика. За сваку слику граф сцене изграђен је само једном, а затим је коришћен за сва питања која се односе на ту слику, чиме је избегнуто вишеструко покретање перцептивне компоненте над истом сликом.

5.6. Директна евалуација перцептивне компоненте

Док претходни експеримент даје укупну тачност комплетног система, циљ овог експеримента јесте да се изоловано испита квалитет перцептивне компоненте. У ту сврху детектовани графови сцена упоређени су са референтним CLEVR анотацијама, како би се посебно проценила успешност детекције објеката, класификације атрибута и формирања просторних релација.

Евалуација је спроведена над подскупом од 1.000 CLEVR слика. За сваку слику најпре је изграђен детектовани граф сцене, а затим је тај граф поређен са одговарајућим референтним описом сцене. Поређење је обухватило четири аспекта: детекциони одзив, тачност класификације атрибута, матрицу конфузије за боје и тачност просторних релација.

Упаривање детектованих и референтних објеката вршено је на основу растојања између њихових центара. Нека су (c_x, c_y) координате центра детектованог објекта, а (p_x, p_y) референтне пикселске

координате одговарајућег објекта. Тада се растојање између њих рачуна као

$$d = \sqrt{(c_x - p_x)^2 + \left(c_y - p_y\right)^2}$$

Објекти су сматрани упареним ако је добијено растојање мање од 50 пиксела. На основу тако добијених парова рачуната је тачност атрибута, при чему су посебно посматрани боја, облик и материјал. Поред тога, за боју је формирана и матрица конфузије, како би се уочиле најчешће замене између појединих класа.

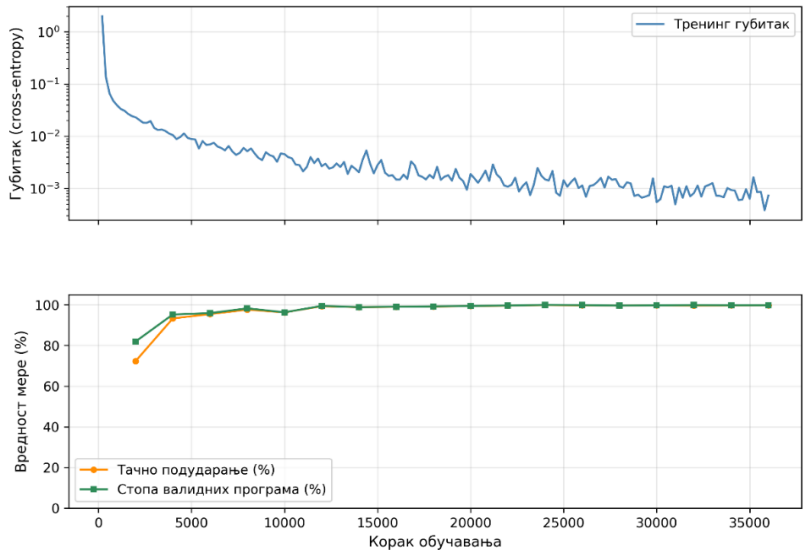
Детекциони одзив мерен је као удео референтних објеката за које је пронађен одговарајући детектовани пар. Тачност просторних релација одређивана је поређењем релација у детектованом и референтном графу сцене, након што су објекти међусобно упарени. На тај начин било је могуће одвојено анализирати грешке које потичу од самог издвајања објеката од грешака у њиховом даљем опису и повезивању у граф сцене.

6. РЕЗУЛТАТИ И ДИСКУСИЈА

У овом поглављу приказани су резултати свих експеримената описаних у поглављу 5. Резултати су организовани по експериментима, а поглавље закључује поређење са сродним радовима из литературе и збирни преглед налаза.

6.1. Резултати додатног обучавања T5-small модела на CLEVR скупу

Резултати обучавања T5-small модела, обученог само на CLEVR паровима питање-програм, приказани су на Слици 6.1 и у Табели 6.1. Слика 6.1 приказује промену вредности губитка током обучавања, као и кретање тачности потпуног поклапања програма и стопе валидних програма на валидационом подскупу.



Слика 6.1. Ток обучавања T5-small модела: промена вредности тренинг губитка, тачности потпуног поклапања програма и стопе валидних програма у зависности од корака обучавања.

Као што се види на Слици 6.1, вредност губитка опада са 1,99 на испод 0,001 у првих 2.000 корака, док тачност потпуног поклапања програма прелази 99% око 12.000. корака, односно након приближно 0,27 епохе. Обучавање је прекинуто после 0,82 епохе услед временског ограничења Colab сесије, али кретање метрика указује на то да је конвергенција достигнута знатно раније, па претпостављамо да наставак обучавања не би донео значајније побољшање.

Завршна евалуација модела приказана је у Табели 6.1. У табели је дата тачност коначног одговора по категоријама питања, као и укупна тачност на подскупу од 1.000 питања CLEVR валидационог скупа у референтном току.

Категорија питања	**Тачност**
`count`	100,0%
`exist`	100,0%
`query`	100,0%
`compare`	100,0%
`other`	99,5%
Укупно	**99,9%**

Табела 6.1. Тачност T5-small модела на CLEVR валидационом скупу у референтном току

Стопа валидних програма износила је 100,0%, а стопа грешке извршавања 0,0%, што значи да у евалуационом подскупу није забележен ниједан неуспешан програм. Укупна тачност од 99,9% показује да модел готово без грешке преводи питања у DSL програме унутар домена на ком је обучаван. Четири категорије достигле су потпун резултат, док је једини пад забележен у категорији `other`, која обухвата неуобичајеније формулације питања. Пошто су и стопа валидних програма и стопа успешног извршавања максималне, добијени резултат може се посматрати као практична горња граница перформанси коју систем може да постигне када перцептивна компонента не уноси додатне грешке.

6.2. Резултати генерализације модула за превођење питања у DSL програме

Резултати евалуације на скуповима који одступају од CLEVR тренинг дистрибуције приказани су у Табели 6.2, заједно са референтним CLEVR резултатом. За CLEVR-Humans приказани су резултати и пре и после додатног обучавања алгоритмом REINFORCE.

Скуп података	Тачност	Стопа валидних програма	Стопа грешке извршавања
CLEVR (референтни)	99,9%	100,0%	0,0%
CLEVR-CoGenT valB	**99,7%**	**100,0%**	**0,1%**
CLEVR-Humans val (пре RL)	41,4%	90,5%	25,5%
CLEVR-Humans val (после RL)	**57,1%**	**92,6%**	**0,6%**

Табела 6.2. Резултати генерализације T5-small модела на дистрибуцијски различитим скуповима у референтном току.

Из Табеле 6.2 види се да модел задржава готово исте перформансе на CLEVR-CoGenT скупу, док на CLEVR-Humans долази до израженог пада и тачности и стабилности извршавања. Ово указује на то да се модел добро носи са новим комбинацијама познатих атрибута, али знатно теже са одступањима у језику и промени самог домена објеката.

На **CLEVR-CoGenT valB** скупу постигнута је тачност од 99,7%, што је занемарљив пад у односу на референтни CLEVR резултат. Стопа валидних програма остала је 100,0%, а стопа грешке извршавања износи свега 0,1%.

Резултат потврђује да DSL-ова потпуна композиционалност омогућава правилно закључивање чак и кад систем наиђе на комбинације атрибута које нису биле заступљене у тренинг скупу.

На **CLEVR-Humans** скупу укупна тачност пада на 41,4% (пре RL). Детаљнији приказ резултата по категоријама питања дат је у Табели 6.3.

Категорија питања	Тачност	Пад у односу на CLEVR
`count`	61,6%	–38,4
`exist`	60,9%	–39,1
`query`	31,4%	–68,6
`compare`	18,7%	–81,3
`other`	21,5%	–78,0
Укупно	**41,4%**	**–58,5**

Табела 6.3. Тачност по категоријама на CLEVR-Humans скупу у референтном току

Стопа валидних програма пала је на 90,5%, а стопа грешке извршавања износи 25,5%. T5 генерише синтаксно исправне, али семантички погрешне програме. Падови су највећи у категоријама `compare` и `other`, јер оне захтевају формулације питања које су знатно удаљене од шаблона видљивих у тренинг скупу. Категорије `count` и `exist` задржавају већу тачност, вероватно зато што и у природнијем језику чешће садрже препознатљиве језичке обрасце.

Додатни увид у природу пада пружа анализа покривености DSL операторима. Од 7.202 питања у CLEVR-Humans валидационом скупу, 88,7% односно 6.389 питања изразиво је постојећим DSL операторима, док преосталих 11,3%, односно 813 питања, садржи конструкције које DSL не подржава. То су, на пример, суперлативи (*farthest*, *largest*), питања о учесталости атрибута (*most common color*) и просторне релације типа *between*. На подскупу изразивом у DSL-у тачност износи 45,7%, наспрам 41,4% на целом скупу, јер нека питања изван покривености модел случајно погоди.

Узроци пада тачности у оквиру подскупа изразивог у DSL-у могу се груписати у три категорије. Прво, CLEVR-Humans питања често

користе синониме за облике, као што су *ball* уместо *sphere* или *box* уместо *cube*, који нису заступљени у CLEVR речнику, па модел не препознаје одговарајући атрибут. Друго, присутне су имплицитне референце у којима питање не наводи све атрибуте потребне за DSL филтрирање. Треће, скраћене и слободније формулације садрже мање контекста него шаблонска CLEVR питања, због чега модел губи структурне информације потребне за генерисање исправног програма.

Ради смањења овог јаза примењен је алгоритам REINFORCE, без иједне програмске анотације из Humans домена. У сваком кораку обучавања модел узоркује четири DSL програма и добија сигнал награде на основу исправности добијеног одговора. Тачност је побољшана са 41,4% на 57,1%, односно за 15,7 процентних поена на кораку 5.000. Стопа грешке извршавања пала је са 25,5% на 0,6%, а стопа грешке парсирања са 9,5% на 7,4%, што указује да REINFORCE имплицитно кажњава програме које симболички извршилац не може да реши. Максимална тачност на резервисаном евалуационом подскупу током обучавања износила је 61,5%, док разлика у односу на финалну вредност на целом валидационом скупу вероватно одражава различиту расподелу примера.

6.3. Резултати директне евалуације перцептивне компоненте

У овом одељку приказани су резултати директне евалуације перцептивне компоненте, спроведене на подскупу од 1.000 CLEVR валидационих слика. Евалуација обухвата квалитет детекције објеката, тачност класификације атрибута по вредностима и тачност одређивања просторних релација.

6.3.1. Квалитет детекције објеката

Први корак у систему представља детекција објеката. YOLOv8m најпре мора да пронађе објекте присутне у сцени, како би CLIP

затим могао да класификује њихове атрибуте. Квалитет детекције приказан је у Табели 6.4.

Мера	Вредност
Одзив (*Recall*)	**97,5%**
Прецизност (*Precision*)	88,7%
F1	92,9%
Тачан број објеката	53,0%
Лажно негативних по слици	0,16
Лажно позитивних по слици	0,80

Табела 6.4. Квалитет детекције YOLOv8m (n=1.000 CLEVR слика).

YOLOv8m показује висок одзив од 97,5%, при чему у просеку само 0,16 референтних објеката по слици остаје непронађено. Нешто нижа прецизност од 88,7% указује на просечно 0,80 лажно позитивних детекција по слици. Број детектованих објеката тачно се поклапа са референтним бројем у 53% слика. Висок одзив је посебно важан за овај систем, јер пропуштен објекат, односно лажно негативна детекција, директно онемогућава проналажење тог објекта у каснијим DSL корацима.

6.3.2. Тачност класификације атрибута

За сваки детектовани регион, CLIP применом *zero-shot* промпт-базиране класификације независно одређује боју, облик, материјал и величину. Тачност по атрибуту приказана је у Табели 6.5.

Атрибут	Тачност
Боја	87,8%
Облик	95,5%
Материјал	94,4%
Величина	92,8%
Просек	**92,6%**

Табела 6.5. Тачност CLIP класификације атрибута.

Класификација облика и материјала постиже високе резултате, са тачностима од 95,5% и 94,4%. Класификација боје је нешто слабија карика, са тачношћу од 87,8%, што значи да је приближно сваки осми објекат погрешно класификован по боји. Класификација величине такође уноси одређену грешку, уз тачност од 92,8%, пре свега због погрешног разврставања великих објеката као малих.

6.3.3. Детаљна анализа грешака перцептивне компоненте

Просечна тачност по атрибуту крије знатне разлике међу вредностима. Табела 6.6 приказује тачност засебно за сваку вредност, откривајући где тачно настају грешке.

Атрибут	Вредност	Тачност
Боја	green	97,0%
	cyan	92,0%
	blue	91,0%
	red	90,0%
	purple	89,0%
	yellow	87,0%
	gray	86,0%
	brown	**71,0%**
Облик	sphere	99,0%
	cylinder	94,0%
	cube	93,0%
Материјал	rubber	96,0%
	metal	93,0%

Величина	small	99,0%
	large	86,0%

Табела 6.6. Тачност класификације по вредностима атрибута.

Унутар категорије боје, *brown* значајно заостаје за осталим класама, са тачношћу од 71%. CLIP је у већем броју случајева класификује као *green*, *yellow* или *red*, вероватно зато што синтетичка браон боја у CLEVR осветљењу личи на затамњене варијанте топлих нијанси. Остале боје крећу се у опсегу од 86% до 97%, при чему сличне нијансе, као што су *cyan* и *blue*, односно *purple* и *gray*, доводе до међусобних замена.

Међу облицима и материјалима грешке су мање изражене. Класе *cylinder* и *cube* повремено се мешају због сличности силуета под одређеним угловима, док до замене између класа *metal* и *rubber* долази код предмета чији одсјај није јасно изражен. Највећи изузетак у категорији величине је *large*, са тачношћу од 86%, где систем губи на тачности јер процена релативне величине захтева глобални контекст сцене, а не само локалне карактеристике детектованог објекта.

Каскадни ефекат ових грешака може се проценити аналитички. За типичан CLEVR програм са три филтра, односно са филтрирањем по боји, облику и материјалу, производ измерених тачности даје:

$$P(\text{сва три филтра ОК}) \approx 0{,}878 \times 0{,}955 \times 0{,}944 \approx 0{,}792$$

Добијена вредност од 79,2% скоро се у потпуности поклапа са измереном тачношћу у детектованом току, која износи 79,0%. Ово потврђује да је CLIP класификација боје, пре свега класе brown, примарни извор грешке у целокупном току обраде.

Поред атрибутске класификације, перцептивна компонента одређује и просторне релације међу објектима. Резултати су приказани у Табели 6.7.

Смер	Тачност
left	66,5%
right	66,7%
front	68,6%
behind	44,3%
Укупно	**61,5%**

Табела 6.7. Тачност просторних релација у детектованом графу сцене.

Релације *left* и *right* постижу тачност од 66,5% до 66,7%. Оне се израчунавају на основу разлике x координата центара детектованих објеката, што је релативно поуздан поступак. Релације *front* и *behind* зависе од монокуларне процене дубине помоћу модела MiDaS. Пошто је његов излаз ординалан, а не метрички, тачност релације *behind* значајно је нижа и износи 44,3%. Укупна тачност просторних релација од 61,5% указује да је ова компонента значајан извор перцепцијске грешке у питањима која захтевају просторно закључивање.

6.4. Резултати евалуације комплетног система

Евалуација комплетног система спроведена је у истој експерименталној поставци за све посматране скупове података. Поред GT тока, у којем се користи референтни граф сцене, посматран је и ток комплетног система са детектованим графом сцене, где се систем ослања на сопствену перцептивну компоненту. Резултати су приказани у Табели 6.8.

Скуп	GT тачност	E2E тачност
CLEVR val	99,9%	79,0%
CoGenT valB	99,7%	79,0%
CLEVR-Humans (пре RL)	41,4%	32,7%
CLEVR-Humans (после RL)	57,1%	45,6%

Табела 6.8. Тачност комплетног система у току са детектованим графом сцене.

На **CLEVR** валидационом скупу, тачност комплетног система износи 79,0%. Разлика у односу на GT ток, где тачност износи 99,9%, последица је грешака перцептивне компоненте, док модул за превођење питања у DSL задржава стабилно понашање.

На **CoGenT B** скупу добија се готово иста тачност комплетног система, што је очекивано јер се ради о истом типу синтетичких сцена, али са другачијом расподелом комбинација атрибута. Са друге стране, CLEVR-Humans представља тежи случај због природнијих и мање шаблонских формулација питања. Пре RL додатног обучавања тачност комплетног система износи 32,7%, док након RL додатног обучавања расте на 45,6%. Овај пораст показује да додатно обучавање на основу сигнала награде побољшава рад система у условима језичке варијабилности, иако грешке перцептивне компоненте и даље ограничавају коначну тачност.

6.5. Поређење резултата са блиским радовима из области

Резултати предложеног система упоређени су са релевантним радовима из области визуелног одговарања на питања над CLEVR скупом. Први важан референтни рад је рад Johnson et al. [2], којим је уведен CLEVR као дијагностички скуп за испитивање композиционог језичког и визуелног резоновања. У том раду евалуирају се класични неуронски модели који директно раде над сликама, без експлицитне програмске синтезе и без симболичког извршавања програма. Најјачи *baseline* модел у том раду, CNN+LSTM+SA+MLP, постиже 73,2% на CLEVR валидационом скупу.

У наставку је поређење фокусирано на IEP [5] и NS-VQA [11], јер су то приступи који су ближи предложеном систему по идеји раздвајања језичког разумевања, визуелне перцепције и резоновања. Резултати су приказани у Табели 6.9.

Скуп	IEP	NS-VQA	Предложени систем
CLEVR val	96,9%	99,8%	79,0% E2E / 99,9% GT
CoGenT B	73,7%	63,9%	79,0% E2E / 99,7% GT
CLEVR-Humans	66,6%	67,0%	45,6% E2E / 57,1% GT

Табела 6.9. Поређење са сродним радовима.

IEP [5] уводи архитектуру која се састоји од генератора програма и неуронског модула за њихово извршавање. Генератор програма је заснован на LSTM моделу, док се извршавање програма врши помоћу *Neural Module Network* приступа. Иако IEP генерише програме, само извршавање није симболичко, већ остаје неуронско. Систем ради директно над сликама, користећи ResNet-101 CNN карактеристике, без експлицитног графа сцене.

На CLEVR валидационом скупу IEP постиже 96,9%, док предложени систем у току комплетног система постиже 79,0%. Међутим, када се користи референтни граф сцене, предложени систем достиже 99,9%. Ова разлика показује да је модул за превођење питања у DSL и симболичко резоновање веома поуздан када је опис сцене тачан, док је пад у току комплетног система пре свега последица грешака перцептивне компоненте.

NS-VQA [11] је архитектурално најсличнији предложеном систему. Он такође раздваја обраду на три дела: анализу сцене, парсирање питања и симболичко извршавање програма. За анализу сцене користи се Mask R-CNN модел обучен на CLEVR сликама са маскама и атрибутима. Атрибути се предвиђају кроз 48 заједничких класа, које представљају комбинације облика, материјала и боје. *Question parser* је заснован на BiLSTM seq2seq моделу, док је егзекутор симболички и користи скуп оператора сличан DSL-у у предложеном систему.

На CLEVR валидационом скупу NS-VQA достиже 99,8%, што је готово идентично резултату предложеног система у GT току, где се постиже 99,9%. То показује да, када је сцена исправно задата,

симболичко резоновање у предложеном систему достиже ниво најуспешнијих неуросимболичких приступа. Разлика у резултату комплетног система настаје зато што NS-VQA користи перцептивни модел посебно обучен на CLEVR сценама, док предложени систем користи општији перцептивни приступ, укључујући CLIP у zero-shot режиму за класификацију атрибута.

На CoGenT B скупу, који испитује композициону генерализацију на нове комбинације боја и облика, NS-VQA бележи значајан пад, са 99,8% на 63,9%. Разлог је у томе што његов заједнички класификатор од 48 класа може да научи корелације између боје и облика присутне у тренинг скупу. IEP такође постиже осетно нижи резултат од 73,7%. Насупрот томе, предложени систем у GT току постиже 99,7%, јер су боја, облик и материјал у DSL-у представљени одвојеним операторима. На тај начин се избегава директно ослањање на фиксне комбинације атрибута. У току комплетног система резултат остаје 79,0%, што је у складу са понашањем система на истом типу синтетичких сцена.

На CLEVR-Humans скупу задатак постаје тежи јер су питања природнија, краћа и мање шаблонска у односу на стандардни CLEVR. IEP након додатног обучавања методом REINFORCE, без GT програма за Humans питања, постиже 66,6%. NS-VQA на истом скупу достиже 67,0%, уз коришћење већег броја програмских анотација и додатног обучавања. Предложени систем у GT току након RL обучавања постиже 57,1%, док у току комплетног система постиже 45,6%.

Ови резултати показују да предложени систем успешно решава симболички део задатка када је граф сцене тачан, али да су коначне перформансе ограничене квалитетом перцептивне компоненте и покривеношћу DSL-а. Посебно на CLEVR-Humans скупу, део питања садржи формулације које нису у потпуности изразиве постојећим DSL операторима, као што су суперлативи, питања о најчешћем атрибуту или просторне релације које нису подржане. Због тога је овај скуп најзахтевнији за предложени систем, али истовремено најбоље показује ограничења и правце за даље унапређење.

7. ЗАКЉУЧАК

У овом раду представљен је неуросимболички систем за визуелно одговарање на питања над сликама, заснован на експлицитном раздвајању перцептивне компоненте и симболичког резоновања. Мотивација за овакав приступ произлази из ограничења потпуно неуронских система, који остварују високу тачност на дијагностичким скуповима, али не пружају транспарентан ни проверљив ток закључивања. Неуросимболичке архитектуре, насупрот томе, омогућавају да се грешка локализује и анализира по фазама, што представља предуслов за систематско унапређење система.

Предложени систем организован је као низ функционално раздвојених модула. Перцептивна компонента из улазне слике гради структурисани граф сцене применом четири модела рачунарског вида: YOLOv8 за детекцију објеката, FastSAM за сегментацију инстанци на нивоу пиксела, MiDaS за процену релативне дубине и CLIP за класификацију визуелних атрибута. Граф сцене је централни интерфејс система, односно структурисану JSON репрезентацију објеката, њихових атрибута и међусобних просторних односа. Модул за резоновање питање на природном језику преводи у извршив DSL програм применом додатно обученог T5-small модела, а затим га детерминистички извршава над графом сцене путем симболичког извршиоца.

Резултати у референтном току показују да модул за превођење питања у DSL програме веома поуздано решава задатак када је граф сцене тачан. На CLEVR валидационом скупу постигнута је тачност од 99,9%, уз стопу валидних програма од 100,0% и стопу грешке извршавања од 0,0%. Овај резултат показује да T5-small успешно савладава формалну структуру DSL-а и да симболички извршилац готово без грешке решава питања унутар домена на ком је модел обучаван.

Испитивање генерализације показало је да систем веома добро подноси нове комбинације познатих атрибута. На CLEVR-CoGenT valB скупу постигнута је тачност од 99,7% у GT току, што је занемарљив пад

у односу на стандардни CLEVR. Такав резултат сугерише да одвојено представљање боје, облика и материјала у DSL-у омогућава добру композициону генерализацију. Насупрот томе, CLEVR-Humans је знатно тежи случај, јер садржи природније, краће и мање шаблонске формулације питања. Пре додатног обучавања помоћу RL, тачност на овом скупу износила је 41,4%, док је након примене алгоритма REINFORCE повећана на 57,1%. Ово показује да се модел може успешно прилагодити природнијем језику и без програмских анотација из Humans домена, користећи само сигнал награде на основу тачности добијеног одговора.

У току комплетног система, где се не користи референтни граф сцене већ граф добијен из слике, тачност на CLEVR валидационом скупу износи 79,0%. Разлика у односу на GT ток последица је грешака перцептивне компоненте, а не самог модула за превођење питања у DSL. Сличан резултат добијен је и на CoGenT B скупу, где тачност комплетног система такође износи 79,0%. На CLEVR-Humans скупу тачност комплетног система након RL додатног обучавања износи 45,6%, што показује да се грешке језичког разумевања и перцептивне грешке у овој поставци сабирају.

Директна евалуација перцептивне компоненте показала је да YOLOv8m постиже висок одзив од 97,5%, што је важно јер пропуштен објекат директно онемогућава његово касније проналажење у DSL програму. Класификација облика и материјала показала се стабилном, са тачностима од 95,5% и 94,4%, док је класификација боје слабија, са тачношћу од 87,8%. Најизраженији проблем јавља се код класе *brown*, која се често меша са класама *green*, *yellow* и *red*. Поред атрибута, значајан извор грешке су и просторне релације. Укупна тачност просторних релација износи 61,5%, при чему је релација *behind* посебно проблематична због ослањања на монокуларну процену дубине.

Поређење са сродним радовима показује да предложени систем у GT току достиже резултате упоредиве са најуспешнијим неуросимболичким приступима. На CLEVR скупу предложени систем постиже 99,9% у GT току, што је практично на нивоу NS-VQA система, који постиже 99,8%. Међутим, у току комплетног система резултат је

нижи због тога што предложени систем користи општију перцептивну компоненту, укључујући CLIP у *zero-shot* режиму, док NS-VQA користи перцептивни модел обучен на CLEVR сценама. На CoGenT B скупу предложени систем показује добру стабилност, јер се не ослања на заједничке класе атрибута које могу научити непожељне корелације између боје и облика. На CLEVR-Humans скупу резултати су нижи у односу на IEP и NS-VQA, али треба имати у виду да предложени систем изолује симболичко резоновање и јасно показује где настају ограничења, пре свега у покривености DSL-а и перцептивној компоненти.

Главна вредност предложеног система није само у постигнутој тачности, већ и у могућности детаљне анализе грешака. За разлику од потпуно неуронских приступа, код којих је тешко одредити због чега је добијен погрешан одговор, овде је могуће раздвојити грешке детекције, класификације атрибута, просторних релација, превођења питања у DSL и симболичког извршавања. Та особина чини систем погодним за даље унапређење, јер се свака компонента може посебно анализирати и заменити бољим решењем.

Као главни правци даљег рада издвајају се побољшање перцептивне компоненте, проширење DSL-а и даље прилагођавање модела природнијим питањима. Перцептивни део могао би се унапредити посебним класификаторима за проблематичне атрибуте, нарочито за боје, као и бољим моделима за процену просторних релација. DSL би се могао проширити операторима који покривају конструкције присутне у CLEVR-Humans скупу, као што су суперлативи, питања о најчешћем атрибуту и сложеније просторне релације. Поред тога, додатно обучавање на мањем броју природније формулисаних питања могло би да повећа робусност модула за превођење питања у програм.

У целини, резултати рада показују да је неуросимболички приступ погодан за задатке визуелног одговарања на питања када је потребно јасно раздвојити перцепцију, разумевање језика и резоновање. Систем постиже веома високу тачност када је граф сцене тачан, добро генерализује на нове комбинације познатих атрибута и омогућава

прецизну анализу ограничења у комплетном току обраде. Иако коначне перформансе зависе од квалитета перцептивне компоненте и покривености DSL-а, предложена архитектура представља добру основу за даљи развој интерпретабилних система за визуелно разумевање сцена.

ЛИТЕРАТУРА

[1] S. Antol, A. Agrawal, J. Lu, M. Mitchell, D. Batra, C. L. Zitnick, and D. Parikh, "VQA: Visual Question Answering," in *Proceedings of the IEEE International Conference on Computer Vision (ICCV)*, 2015, pp. 2425-2433.

[2] Johnson, J., Hariharan, B., van der Maaten, L., Fei-Fei, L., Zitnick, C. L., & Girshick, R. (2017). CLEVR: A Diagnostic Dataset for Compositional Language and Elementary Visual Reasoning. *IEEE Conference on Computer Vision and Pattern Recognition (CVPR).*

[3] J. Andreas, M. Rohrbach, T. Darrell, and D. Klein, "Neural Module Networks," in *Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition (CVPR)*, 2016, pp. 39-48.

[4] R. Hu, J. Andreas, M. Rohrbach, T. Darrell, and K. Saenko, "Learning to Reason: End-to-End Module Networks for Visual Question Answering," in *Proceedings of the IEEE International Conference on Computer Vision (ICCV)*, 2017, pp. 804-813.

[5] J. Johnson, B. Hariharan, L. van der Maaten, J. Hoffman, L. Fei-Fei, C. L. Zitnick, and R. Girshick, "Inferring and Executing Programs for Visual Reasoning," in *Proceedings of the IEEE International Conference on Computer Vision (ICCV)*, 2017, pp. 2989-2998.

[6] E. Perez, F. Strub, H. de Vries, V. Dumoulin, and A. Courville, "FiLM: Visual Reasoning with a General Conditioning Layer," in *Proceedings of the AAAI Conference on Artificial Intelligence*, vol. 32, no. 1, 2018.

[7] D. A. Hudson and C. D. Manning, "Compositional Attention Networks for Machine Reasoning," in *International Conference on Learning Representations (ICLR)*, 2018.

[8] D. A. Hudson and C. D. Manning, "GQA: A New Dataset for Real-World Visual Reasoning and Compositional Question Answering," in

Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR), 2019, pp. 6700-6709.

[9] T. Gupta and A. Kembhavi, "Visual Programming: Compositional Visual Reasoning Without Training," in *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR)*, 2023, pp. 14953-14962.

[10] D. Surís, S. Menon, and C. Vondrick, "ViperGPT: Visual Inference via Python Execution for Reasoning," in *Proceedings of the IEEE/CVF International Conference on Computer Vision (ICCV)*, 2023, pp. 11888-11898.

[11] K. Yi, J. Wu, C. Gan, A. Torralba, P. Kohli, and J. B. Tenenbaum, "Neural-Symbolic VQA: Disentangling Reasoning from Vision and Language Understanding," in *Advances in Neural Information Processing Systems 31 (NeurIPS 2018)*, 2018.

[12] I. Goodfellow, Y. Bengio, and A. Courville, *Deep Learning*. Cambridge, MA, USA: MIT Press, 2016.

[13] D. E. Rumelhart, G. E. Hinton, and R. J. Williams, "Learning representations by back-propagating errors," *Nature*, vol. 323, pp. 533-536, 1986.

[14] Y. LeCun, L. Bottou, Y. Bengio, and P. Haffner, "Gradient-Based Learning Applied to Document Recognition," *Proceedings of the IEEE*, vol. 86, no. 11, pp. 2278-2324, 1998.

[15] J. Redmon, S. Divvala, R. Girshick, and A. Farhadi, "You Only Look Once: Unified, Real-Time Object Detection," in *Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition (CVPR)*, 2016, pp. 779-788.

[16] G. Jocher, A. Chaurasia, and J. Qiu, "Ultralytics YOLOv8," 2023. [Computer software].Available: https://github.com/ultralytics/ultralytics

[17] X. Zhao, W. Ding, Y. An, Y. Du, T. Yu, M. Li, M. Tang, and J. Wang, "Fast Segment Anything," *arXiv preprint arXiv:2306.12156*, 2023.

[18] R. Ranftl, K. Lasinger, D. Hafner, K. Schindler, and V. Koltun, "Towards Robust Monocular Depth Estimation: Mixing Datasets for Zero-Shot Cross-Dataset Transfer," *IEEE Transactions on Pattern Analysis and Machine Intelligence*, vol. 44, no. 3, pp. 1623-1637, 2022.

[19] A. Radford, J. W. Kim, C. Hallacy, A. Ramesh, G. Goh, S. Agarwal, G. Sastry, A. Askell, P. Mishkin, J. Clark, G. Krueger, and I. Sutskever, "Learning Transferable Visual Models From Natural Language Supervision," in *Proceedings of the 38th International Conference on Machine Learning*, PMLR, vol. 139, 2021, pp. 8748-8763.

[20] A. Vaswani, N. Shazeer, N. Parmar, J. Uszkoreit, L. Jones, A. N. Gomez, Ł. Kaiser, and I. Polosukhin, "Attention Is All You Need," in *Advances in Neural Information Processing Systems 30 (NeurIPS 2017)*, 2017.

[21] C. Raffel, N. Shazeer, A. Roberts, K. Lee, S. Narang, M. Matena, Y. Zhou, W. Li, and P. J. Liu, "Exploring the Limits of Transfer Learning with a Unified Text-to-Text Transformer," *Journal of Machine Learning Research*, vol. 21, no. 140, pp. 1-67, 2020.

[22] H. Touvron, T. Lavril, G. Izacard, X. Martinet, M.-A. Lachaux, T. Lacroix, B. Rozière, N. Goyal, E. Hambro, F. Azhar, A. Rodriguez, A. Joulin, E. Grave, and G. Lample, "LLaMA: Open and Efficient Foundation Language Models," *arXiv preprint arXiv:2302.13971*, 2023.

[23] T. B. Brown et al., "Language Models are Few-Shot Learners," in *Advances in Neural Information Processing Systems 33 (NeurIPS 2020)*, 2020, pp. 1877-1901.

[24] R. J. Williams, "Simple Statistical Gradient-Following Algorithms for Connectionist Reinforcement Learning", Machine Learning, vol. 8, no. 3-4, pp. 229-256, 1992.

[25] PyTorch, "torch.hub." https://docs.pytorch.org/docs/2.11/hub.html [датум приступа 26.04.2026.]

[26] OpenCV, "OpenCV-Python Tutorials: Morphological Transformations." https://docs.opencv.org/4.x/d9/d61/tutorial_py_morphological_ops.html [датум приступа 26.04.2026.]

[27] T. Wolf et al., “Transformers: State-of-the-Art Natural Language Processing,” in *Proceedings of the 2020 Conference on Empirical Methods in Natural Language Processing: System Demonstrations*, 2020, pp. 38-45.

[28] Google, “Google Colaboratory.” https://colab.research.google.com/ [датум приступа 26.04.2026.]

БИОГРАФИЈА

Богдан Ђукић је рођен 26.06.2002. године у Сомбору. Основну школу завршио је у Раткову, а средњу школу у Оџацима. Школске 2021/2022. године уписао је Факултет техничких наука Универзитета у Новом Саду на студијски програм Рачунарство и аутоматика, на којем се најпре усмерио на модул Примењене рачунарске науке и информатика, а затим на Интелигентне системе. Током студија развио је интересовање за области машинског учења, вештачке интелигенције и развоја комплексних софтверских система. Положио је све испите предвиђене наставним планом и програмом и стекао услов за одбрану завршног рада под насловом „*Визуелно разумевање сцене кроз неуросимболичко резоновање*“.